



西安交通大学
XI'AN JIAOTONG UNIVERSITY

实验报告

——图像生成大作业

课程名称:	数字图像与视频处理
姓名:	周湛昊
学院:	电信学部
班级:	自动化 2305
学号:	2233712088

2026 年 5 月 8 日

摘要

本实验基于开源框架 IDDM (Integrated Design Diffusion Model), 在 cifar-10 数据集和 animate-face 数据集上训练条件扩散模型, 实现对 10 个类别和动画人脸风格图像的生成。通过调整训练参数 (启用 AMP 混合精度、增大 batch size、多进程数据加载), 在 RTX 4090 GPU 上完成训练, 最终生成图像, cifar-10 数据集的 FID 评估得分为 44.60, animate-face 数据集的 FID 评估得分为 143.37。

一、方法原理

1.1 DDPM (Denoising Diffusion Probabilistic Model)

DDPM 是一类基于马尔可夫链的生成模型, 包含前向加噪过程与反向去噪过程:

前向过程 (加噪):

$$q(x_t|x_0) = \mathcal{N} \left(\sqrt{\bar{\alpha}_t} x_0, (1 - \bar{\alpha}_t) I \right)$$

其中 $\bar{\alpha}_t = \prod_{s=1}^t (1 - \beta_s)$, β_t 为噪声调度 (本实验使用 linear schedule, $T = 1000$)。

反向过程 (去噪):

训练一个 U-Net $\epsilon_\theta(x_t, t, y)$ 预测添加的噪声, 损失函数为 MSE:

$$\mathcal{L} = \mathbb{E}_{x_0, \epsilon, t} [\|\epsilon - \epsilon_\theta(x_t, t, y)\|^2]$$

采样: 从 $x_T \sim \mathcal{N}(0, I)$ 出发, 迭代去噪还原 x_0 。

1.2 条件生成与 CFG (Classifier-Free Guidance)

为实现按类别生成, 模型同时学习有条件分布 $\epsilon_\theta(x_t, t, y)$ 和无条件分布

$\epsilon_\theta(x_t, t, \emptyset)$ (训练时以概率随机丢弃标签)。

采样时通过 CFG 放大类别信号:

$$\hat{\epsilon} = \epsilon_\theta(x_t, t, \emptyset) + w [\epsilon_\theta(x_t, t, y) - \epsilon_\theta(x_t, t, \emptyset)]$$

w (cfg_scale) 控制生成图像与条件的一致性强度。本实验最佳配置为 $w = 3$ 。

1.3 DPM-Solver++ 2M（高阶采样器）

将反向去噪过程建模为半线性常微分方程（ODE），采用 2 阶多步数值求解，仅需 **20 步**即可达到接近 DDIM 100 步的生成质量，大幅提升采样效率。

1.4 EMA（Exponential Moving Average）

为稳定推理质量，维护训练权重 θ 的指数滑动平均：

$$\theta^{\text{ema}} \leftarrow \mu \theta^{\text{ema}} + (1 - \mu) \theta, \quad \mu \approx 0.999$$

推理时使用 EMA 权重，可过滤梯度噪声，通常比最新训练权重的 FID 更低。

1.5 FID（Fréchet Inception Distance）

FID 将生成图像集与参考图像集分别输入 InceptionV3 提取 2048 维特征，拟合多元高斯分布 (μ, Σ) ，计算：

$$\text{FID} = \|\mu_r - \mu_g\|^2 + \text{Tr} \left(\Sigma_r + \Sigma_g - 2(\Sigma_r \Sigma_g)^{1/2} \right)$$

FID 越小代表生成分布越接近真实数据分布，生成质量越高。

二、实验设置

2.1 数据集

cifar-10: 10 类，共 50000 张训练图（每类 5000 张），原始分辨率 32×32 ，训练时由 dataloader 上采样至 64×64 。

animate-face: 整理为 torchvision.datasets.ImageFolder 可读取的结构：

datasets/animate-face/

```
└── class 1/  
    ├── *.png  
    └── ...
```

2.2 模型与训练配置

cifar-10:

参数	值
网络结构	条件 U-Net (act=gelu, num_classes=10)
噪声调度	Linear, $T = 1000$
优化器	AdamW, lr=3e-4, linear schedule
训练 epoch	50 (隔 10 epoch 保存一次中间权重)
每卡 batch size	16 (3 卡 DDP, 等效 batch 48)

参数	值
混合精度	AMP (FP16/BF16)
数据加载线程	num_workers=4
训练硬件	RTX 4090

animate-face:

参数	值
网络结构	无条件 U-Net (act=gelu)
噪声调度	Linear, $T = 1000$
优化器	AdamW, lr=3e-4, linear schedule
训练 epoch	100
每卡 batch size	8 (3 卡 DDP, 等效 batch 24)
混合精度	AMP
数据加载线程	num_workers=4
训练硬件	RTX 4090

2.3 评估配置

cifar-10:

参数	值
推理权重	EMA (--use_ema)
采样器	DPM-Solver++ 2M, 20 步
cfg_scale (推理)	3 (最佳); 对照实验含 1
生成数量	每类 500 张, 共 5000 张
参考集	cifar-10 训练集 50000 张 (resize 至 64×64 , 路径 results/cifar_exp1/cifar_ref64_all/)
FID 工具	iddm/tools/FID_calculator_plus.py, dims=2048

animate-face:

参数	值
推理权重	ckpt_last.pt
采样器	DDIM
生成数量	256 张
参考集	从训练集取 256 张并 resize 至 64×64
FID 工具	iddm/tools/FID_calculator_plus.py, dims=2048

三、训练过程

3.1 训练命令

```
export CUDA_VISIBLE_DEVICES=2,3,4
export PYTORCH_CUDA_ALLOC_CONF=expandable_segments:True
python iddm/tools/train.py \
    --seed 0 --conditional --mode class \
    --sample ddpm --network unet --act gelu \
    --noise_schedule linear --loss mse --optim adamw \
    --lr 3e-4 --lr_func linear \
    --image_size 64 --batch_size 16 --num_workers 4 \
    --epochs 50 \
    --save_model_interval --save_model_interval_epochs 10 \
    --amp \
    --run_name cifar_exp2 \
    --dataset_path datasets/cifar10 \
    --result_path results \
    --distributed --world_size 3 --main_gpu 0 --use_gpu 0 \
    --cfg_scale 3 --vis --num_vis 10 --image_format png
```

3.2 完整训练日志（每 Epoch Loss）

cifar-10:

训练总耗时约 **3 小时 11 分**（单 epoch ≈ 3.8 min）。

Epoch	Train Loss	Epoch	Train Loss	Epoch	Train Loss
0	0.065222	17	0.010527	34	0.010207
1	0.019439	18	0.011169	35	0.010361
2	0.016548	19	0.010984	36	0.010288
3	0.014940	20	0.010885	37	0.010348
4	0.013178	21	0.010947	38	0.010234
5	0.012532	22	0.010789	39	0.010235
6	0.012155	23	0.010625	40	0.010852
7	0.012155	24	0.010669	41	0.010236
8	0.011822	25	0.010754	42	0.010245
9	0.011814	26	0.010649	43	0.010287
10	0.011474	27	0.010872	44	0.010333
11	0.011355	28	0.010398	45	0.010397
12	0.011006	29	0.010615	46	0.010508
13	0.010847	30	0.010660	47	0.010447

Epoch	Train Loss	Epoch	Train Loss	Epoch	Train Loss
14	0.011039	31	0.010772	48	0.010282
15	0.011041	32	0.010341	49	0.010127
16	0.010943	33	0.010761		


animate-face:

训练总 wall time 约 **1 小时 14 分**（含中途续训间隔）。Loss 从 epoch 0 的 0.0852 快速下降到 epoch 10 的 0.0233，此后进入缓慢收敛阶段，最终稳定在 0.0205 附近。


Epoch	Train Loss	Epoch	Train Loss
0	0.085213	1	0.037755
2	0.032625	3	0.029435
4	0.028528	5	0.026625
6	0.025783	7	0.024698
8	0.023222	9	0.023991
10	0.023340	11	0.022928
12	0.024332	13	0.023796
14	0.022560	15	0.022587
16	0.023654	17	0.021583
18	0.022776	19	0.022118
20	0.021753	21	0.021388
22	0.021328	23	0.022005
24	0.021345	25	0.020983
26	0.020913	27	0.021977
28	0.020180	29	0.021124
30	0.020676	31	0.021415
32	0.020841	33	0.021265
34	0.020721	35	0.021511
36	0.020536	37	0.020249
38	0.021452	39	0.020976
40	0.021407	41	0.020539
42	0.020105	43	0.020571
44	0.020574	45	0.020232
46	0.020293	47	0.021085
48	0.020452	49	0.020505

3.3 Loss 曲线

cifar-10:



animate-face:




四、图像生成结果

4.1 生成命令


```
export CUDA_VISIBLE_DEVICES=2
for CFG in 3 1; do
    python scripts/generate_per_class.py \
        --weight_path results/cifar_exp2/ckpt_last.pt \
        --out_root results/cifar_exp2/eval_ema/cfg${CFG}_dpmpp2m \
        --per_class 500 --batch_size 50 \
        --sample dpmpp2m --cfg_scale $CFG \
        --use_ema --use_gpu 0 --image_size 64
done # 以 cifar-10 数据集为例
```

4.2 各类别生成样本

cifar-10:



animate-face:



五、FID 评估

5.1 整体 FID 结果

cifar-10:

配置	cfg_scale	生成数	FID ↓
EMA + DPM-Solver++ 2M (20 步)	3	5000	44.60
EMA + DPM-Solver++ 2M (20 步)	1	5000	64.74

animate-face:

配置	采样器	生成数	参考数	FID ↓
ckpt_last.pt	DDIM	256	256	143.37

5.2 cifar-10 数据集的各类别 FID (cfg=3, 500 生成 vs 5000 参考)

类别 ID	类别名称	FID ↓
0	airplane	107.77
1	automobile	78.17
2	bird	130.53
3	cat	136.40
4	deer	89.82
5	dog	107.49
6	frog	106.58
7	horse	75.16
8	ship	92.24
9	truck	63.66
—	平均	98.78

六、结论

- 训练 epoch 是 FID 的主导因素**: CIFAR-10 数据集仅用 50 epoch 的自训练模型 (FID=44.60) 已大幅优于 10 epoch 基线 (FID=134.67)。
- CFG 强度在充分训练后有效**: 50 epoch 后 cfg=3 优于 cfg=1 (44.60 < 64.74), 一旦模型的条件分布学到位, 增大 CFG 强度可改善生成图像与类别标签的一致性。
- 采样效率提升**: DPM-Solver++ 2M 以 20 步达到良好生成质量, 相比 DDIM 100 步节省 5× 采样时间, 同时 FID 更低。
- animate-face 数据集当前生成效果一般**: FID=143.37 表明 50 epoch 训练和 256 张样本评估下, 生成分布与参考集仍有明显差距, 同时肉眼可见生成的图片还有很多噪点且有的人物扭曲。后续可增加生成数量到 5000 张, 并尝试 EMA 权重、更多采样器或更优采样步数。