图像与视频处理
Image an Video Processing

第十一讲：图像恢复

人工智能与机器人研究所
Institute of Artificial Intelligence and Robotics

兰旭光

目录

- 退化-恢复模型
- 噪声模型
- 空域滤波器恢复
- 频域滤波恢复
- 线性位置不变退化
- 退化函数估计
- 逆滤波器
- 维纳滤波器-最小均方误差
- 约束最少方差滤波器
- 几何均值滤波器

目录

- 退化-恢复模型
- 噪声模型
- 空域滤波器恢复
- 频域滤波恢复
- 线性位置不变退化
- 退化函数估计
- 逆滤波器
- **维纳滤波器-最小均方误差**
- 约束最少二乘滤波器
- 几何均值滤波器

Minimum Mean Square Error (Wiener) Filtering 最小均方误差（维纳）滤波器

- **N. Wiener (1942)**

- **Objective**
  查找未损坏图像的估计值，以便将它们之间的均方误差最小化

$$e^2 = E\left\{(f - \hat{f})^2\right\}$$

Why Wiener filter?

- The Wiener filter is a linear filter that is optimal in the sense that it minimizes the mean square error between the undistorted image f(x,y) and the restored image $\hat{f}(x,y)$

- i.e. it minimizes

$$e^2 = E\left[\left|f - \hat{f}\right|^2\right]$$

维纳滤波器是一种线性滤波器，从某种意义上说，它是最佳的，因为它最大限度地减少了未失真图像 f（x，Y）和恢复图像之间的最小均方误差

Norbert Wiener,
USA,
1894-1964

美国应用数学家，控制论的创始人，在电子工程方面贡献良多。Cybernetics
Or control and communication in the animal and the machine

三岁读写，三年时间读完中学，1913年，18岁获得哈佛博士学位

维纳滤波器

- 维纳过滤器由诺伯特•维纳于 1940 年提出（1949 年出版）
  - 其目的是减少信号中的噪声量
  - 维纳滤波器不是自适应滤波器，因为它假设输入是静止的
  - 维纳滤波是一种统计方法
  - 性能标准：最小均方误差（MMSE）

维纳滤波器

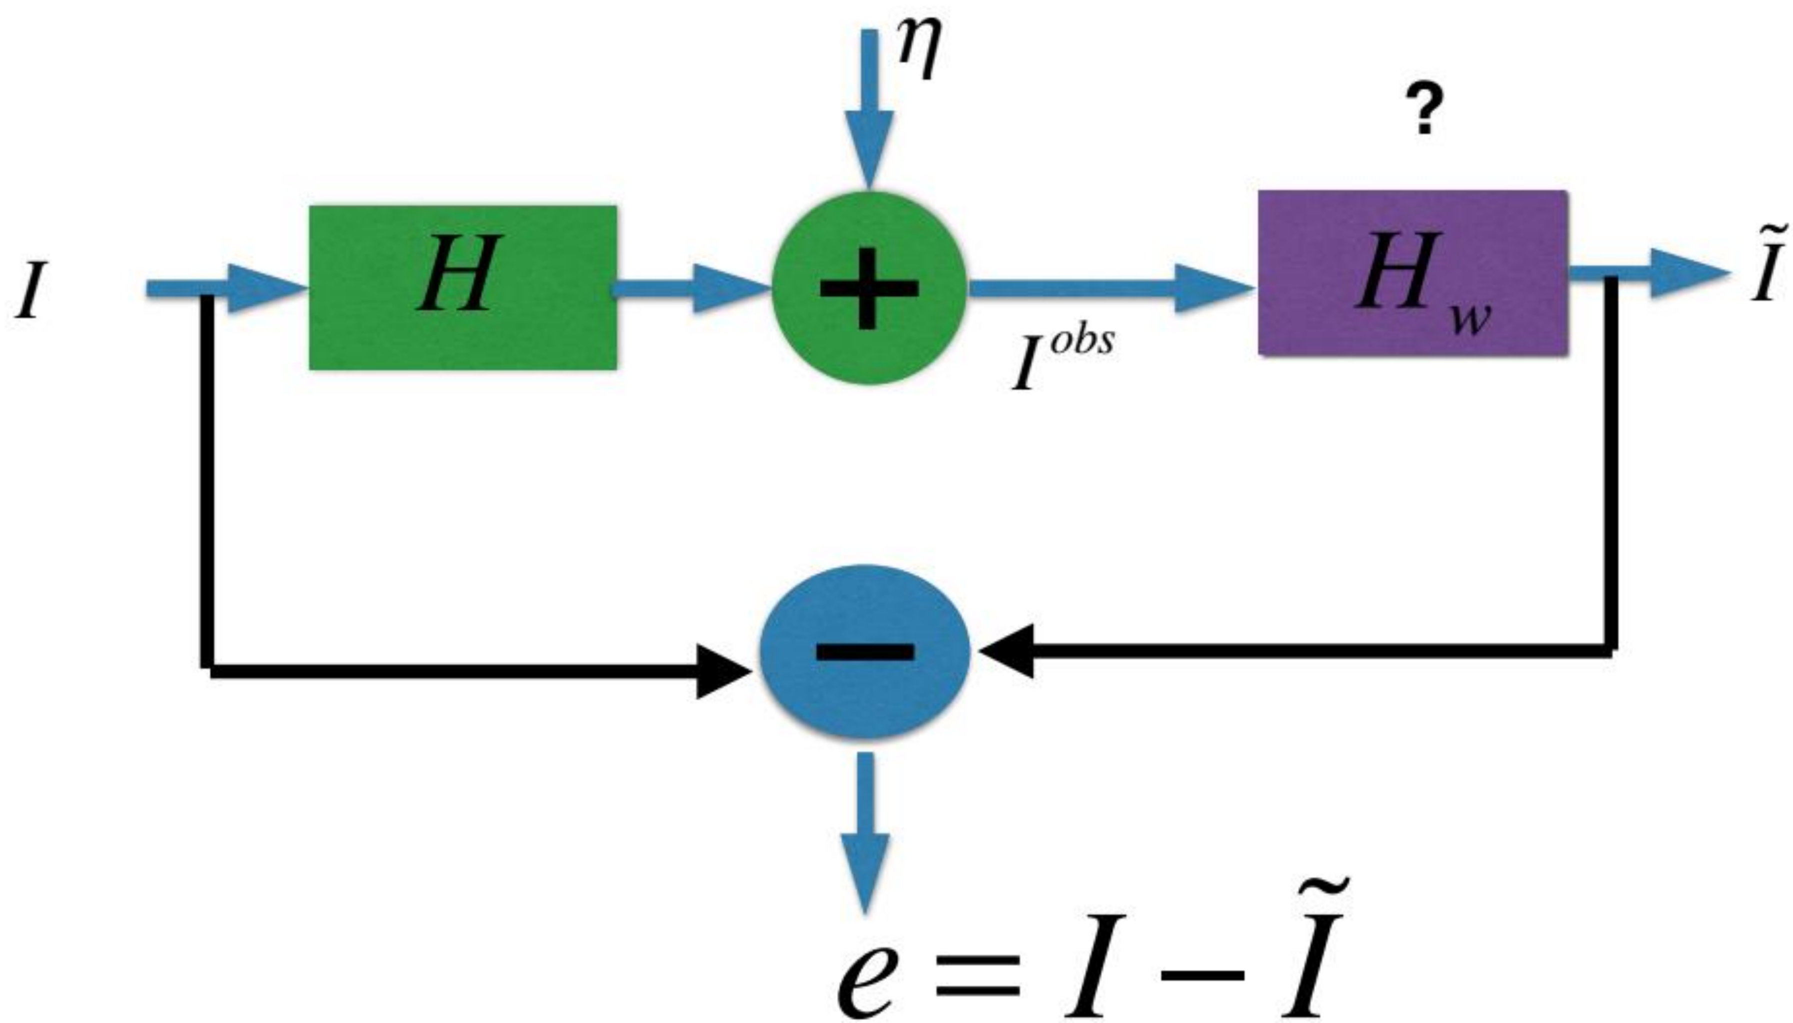

Orthogonality Principle

正交性原则

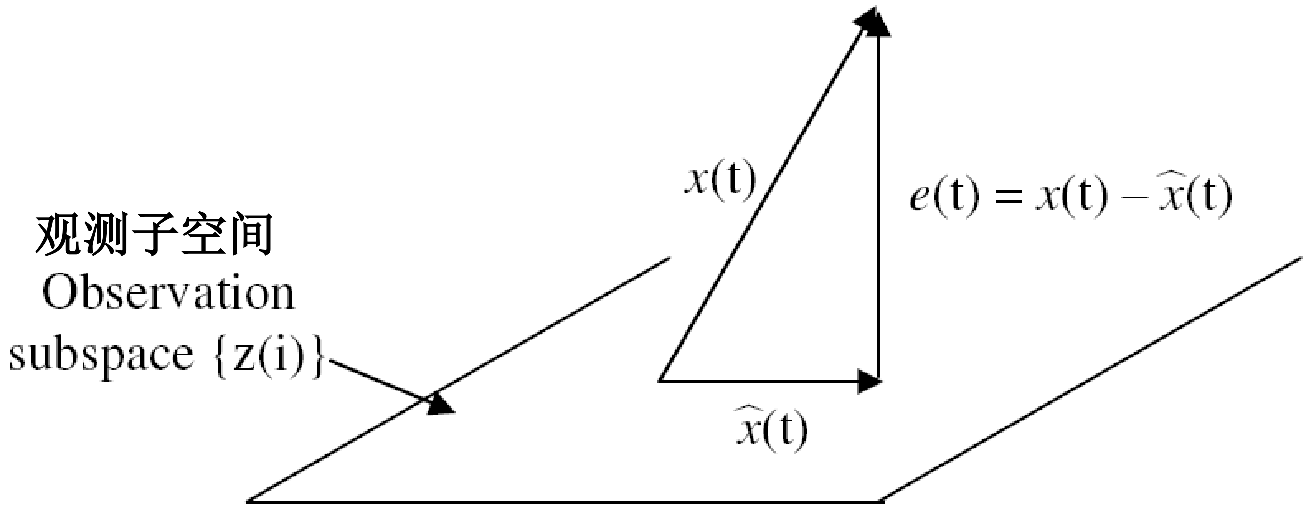

Figure 2: Projection of signal onto the observation subspace

信号在观测子空间上的投影

- Idea: To get the minimum error in the MSE sense, the observation subspace has to be orthogonal to the estimation-error subspace.
  为了获得**MSE**的最小误差，观测子空间必须与估计误差子空间正交。

1）正交性原则

Best Linear Estimator 最佳线性估计

In this case the estimator $\hat{Y}$ is a linear function of the observations $X_1, X_2, \cdots, X_n$. Thus 线性函数

$$\hat{Y}_l = a_1 X_1 + a_2 X_2 + \cdots + a_n X_n = \sum_{i=1}^{n} a_i X_i. \tag{16-15}$$

where $a_1, a_2, \cdots, a_n$ are unknown quantities to be determined. The mean square error is given by $(\varepsilon = Y - \hat{Y}_l)$ 需要确定的未知系数

$$E\{|\varepsilon|^2\} = E\{|Y - \hat{Y}_l|^2\} = E\{|Y - \sum a_i X_i|^2\} \tag{16-16}$$

and under the MMSE criterion $a_1, a_2, \cdots, a_n$ should be chosen so that the mean square error $E\{|\varepsilon|^2\}$ is at its minimum possible value. Let σ_n^2 represent that minimum possible value. Then 处于其最小可能值

$$\sigma_n^2 = \min_{a_1, a_2, \cdots, a_n} E\{|Y - \sum_{i=1}^{n} a_i X_i|^2\}. \tag{16-17}$$

To minimize (16-16), we can equate

$$\frac{\partial}{\partial a_k} E\{|\varepsilon|^2\} = 0, \quad k = 1, 2, \cdots, n. \tag{16-18}$$

This gives

$$\frac{\partial}{\partial a_k} E\{|\varepsilon|^2\} = E\left\{\frac{\partial |\varepsilon|^2}{\partial a_k}\right\} = 2E\left[\varepsilon \left\{\frac{\partial \varepsilon}{\partial a_k}\right\}^*\right] = 0. \tag{16-19}$$

But

$$\frac{\partial \varepsilon}{\partial a_k} = \frac{\partial (Y - \sum_{i=1}^{n} a_i X_i)}{\partial a_k} = \frac{\partial Y}{\partial a_k} - \frac{\partial (\sum_{i=1}^{n} a_i X_i)}{\partial a_k} = -X_k. \tag{16-20}$$

Substituting (16-19) in to (16-18), we get
代入

$$\frac{\partial E\{|\varepsilon|^2\}}{\partial a_k} = -2E\{\varepsilon X_k^*\} = 0,$$

or the best linear estimator must satisfy 最佳线性估计必须满足

$$E\{\varepsilon X_k^*\} = 0, \quad k = 1, 2, \cdots, n. \tag{16-21}$$

估计误差

Notice that in (16-21), ε represents the estimation error $(Y - \sum_{i=1}^{n} a_i X_i)$, and $X_k, \ k = 1 \to n$ represents the data. Thus from (16-21), the error ε is orthogonal to the data $X_k, \ k = 1 \to n$ for the best linear estimator. 误差和数据正交

In other words, in the linear estimator (16-15), the unknown constants $a_1, a_2, \cdots, a_n$ must be selected such that the error $\varepsilon = Y - \sum_{i=1}^{n} a_i X_i$ is orthogonal to every data $X_1, X_2, \cdots, X_n$ for the best linear estimator that minimizes the mean square error.最小化均方误差

2）随机过程——基本概念

- **确定性和随机性过程：**
- **都是时间的连续函数（通常），数学概念**

- **确定性过程:**

  物理过程由显式数学关系表示

- **例子：**

  实验室中单个质量弹簧阻尼器在自由振动中的响应

- **随机过程:**

  大量不同原因的结果。用概率术语和平均值属性描述

2）随机过程——基本概念

- **随机过程:**

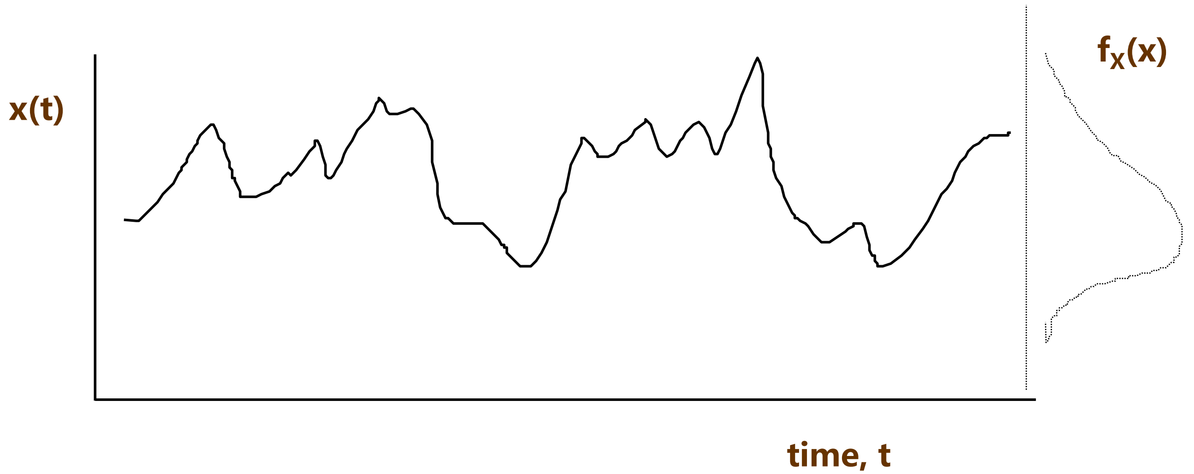

- **概率密度函数描述了随机过程幅度的一般分布，但它没有给出过程的时间或频率内容的信息**

2）随机过程——基本概念

• 平均和平稳性

- Underlying process底层过程
- 样本记录是底层过程的个体表示

- Ensemble averaging 累加平均

  该过程的性质是利用相应时刻的值对样本记录的集合或"集合"进行平均得到的

- Time averaging时间平均

  通过对单个记录在时间上求平均得到

累加平均:

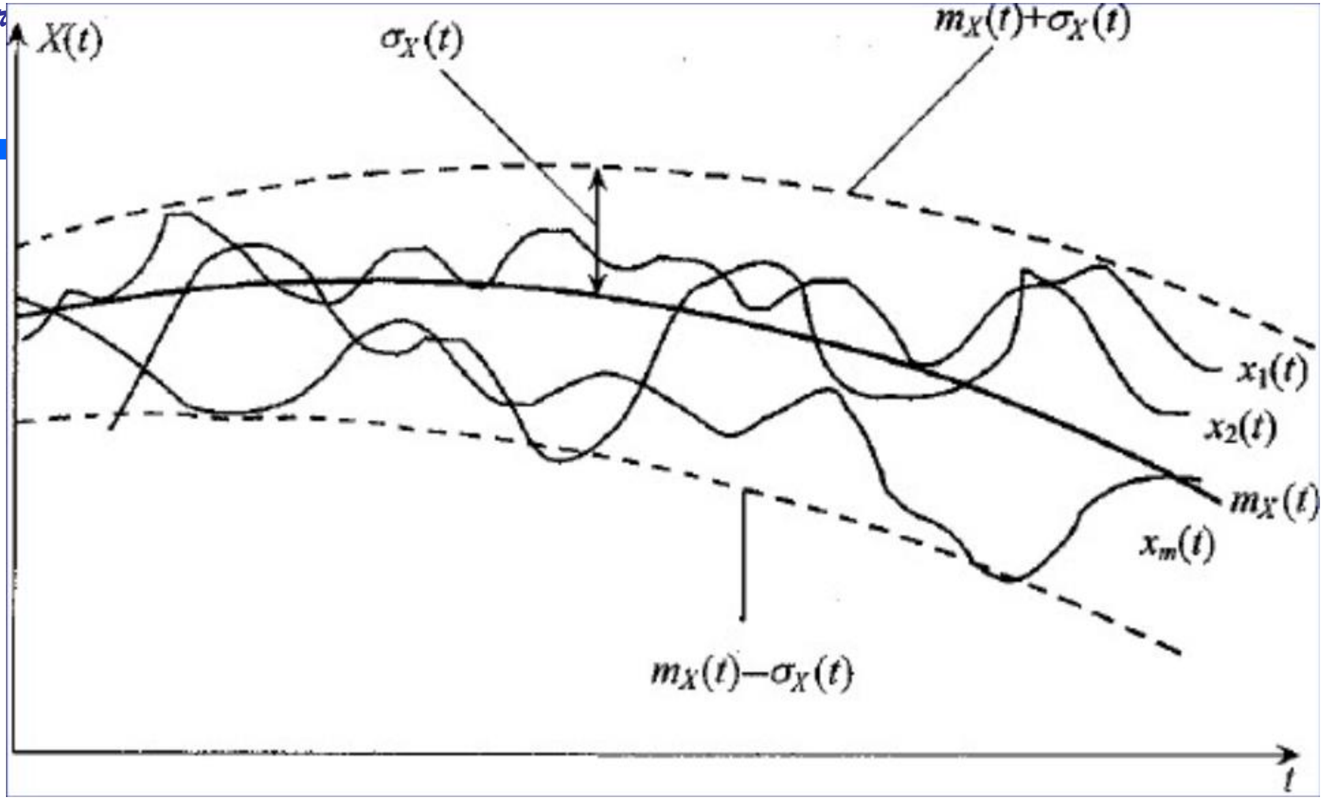

统计均值是对随机过程中**所有样本函数**在时间t的所有取值进行概率加权平均，所以又称为**集合平均**。它反映了样本函数统计意义下的平均变化规律， 是所有样本函数在各个时刻摆动的中心。

2）随机过程——基本概念

- **Stationary random process :**
  - **Ensemble averages do not vary with time**

- **Ergodic process 各态历经:**

平稳过程，其中来自单个记录的平均值与从整体上平均获得的平均值相同

Most stationary random processes can be treated as ergodic

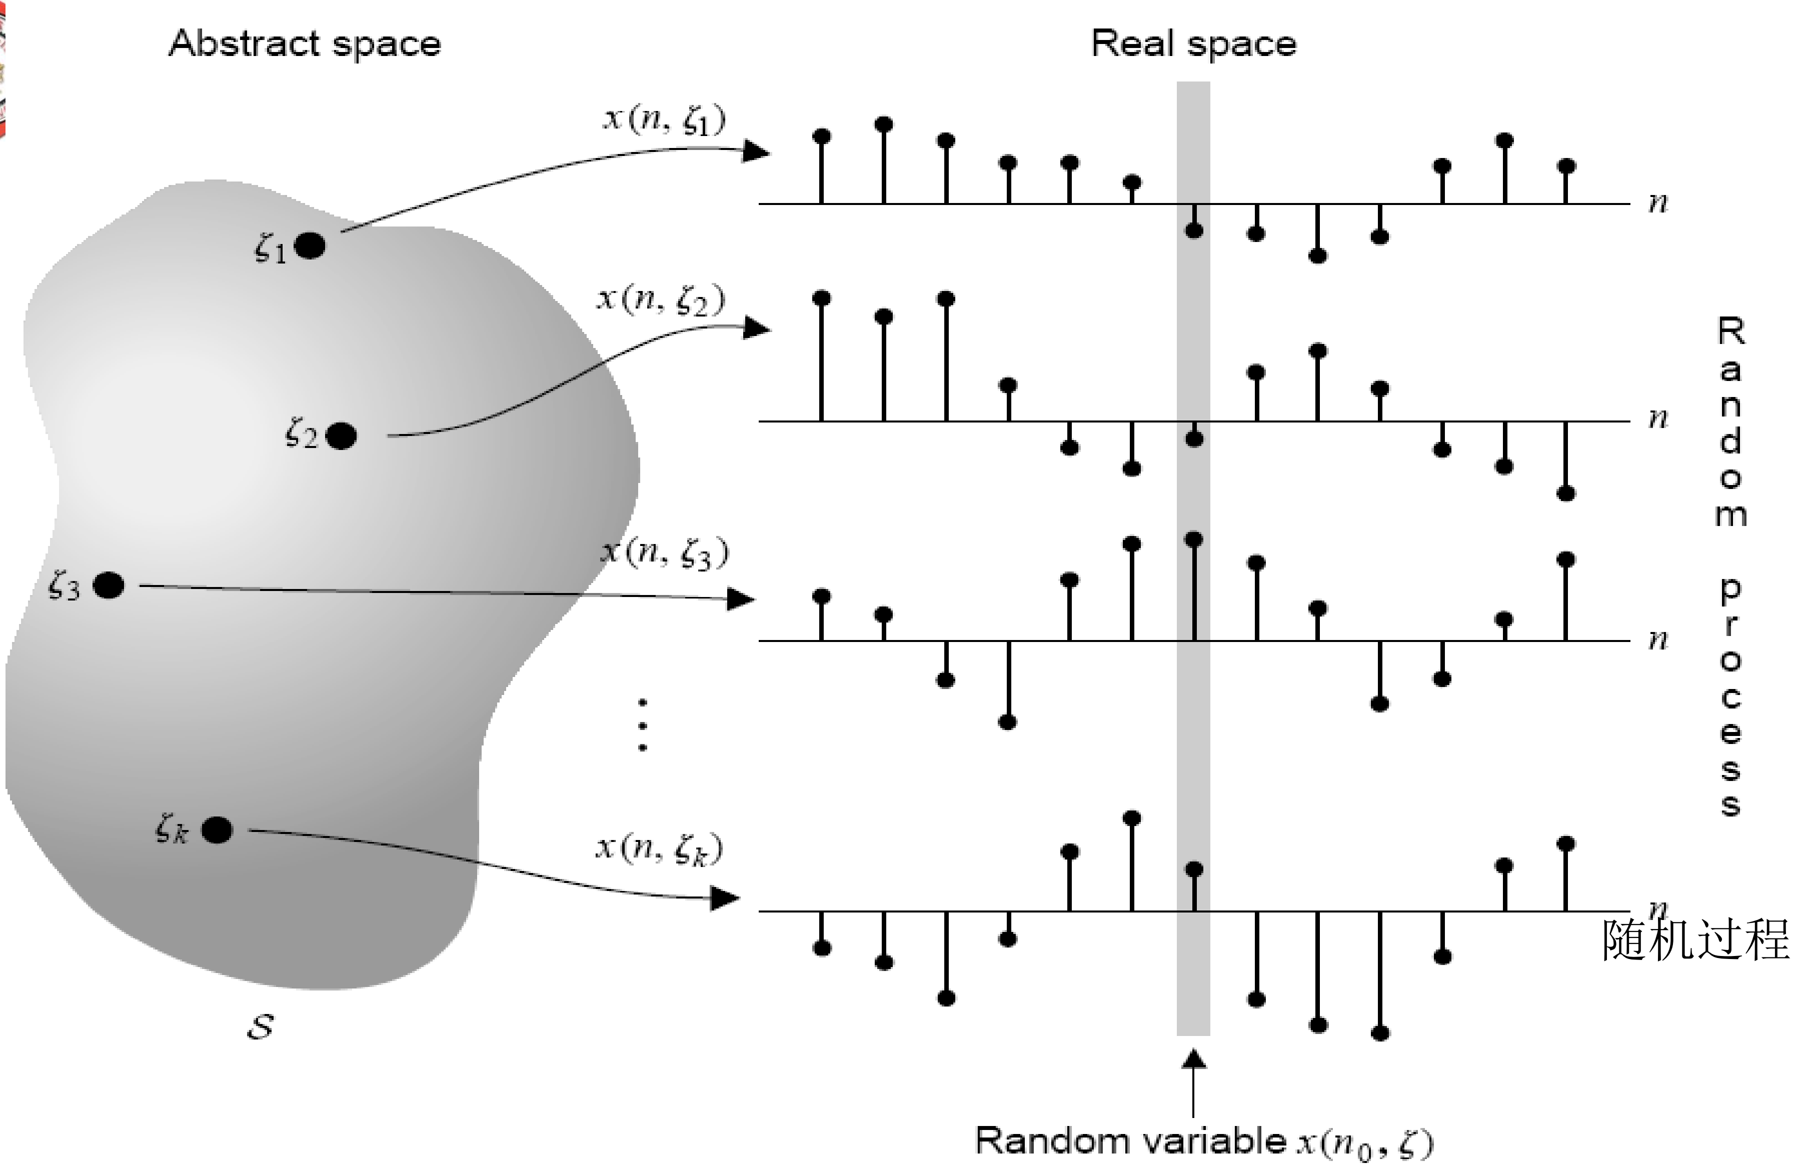

随机变量

- $x(n, \zeta)$ is a random variable if n is *fixed* and ζ is a variable.
- $x(n, \zeta)$ is a sample sequence if ζ is *fixed* and n is a variable.
- $x(n, \zeta)$ is a number if both n and ζ are *fixed*.
- $x(n, \zeta)$ is a stochastic process if both n and ζ are variables.

Random variables 随机变量

Definitions

- Joint probability distribution function: 联合分布函数

$$F_{x,y}(\alpha,\beta)=\Pr\{x\le\alpha, y\le\beta\}$$

- Joint probability density function: 联合概率密度函数

$$f_{x,y}(\alpha,\beta)=\frac{\partial^2}{\partial\alpha\partial\beta}F_{x,y}(\alpha,\beta)$$

- Correlation: 相关性

$$r_{xy}=E\{xy^*\}$$

- Covariance: 协方差

$$c_{xy}=\mathrm{Cov}(x,y)=E\{(x-m_x)(y-m_y)^*\}=r_{xy}-m_x m_y^*$$

- Correlation coefficient 相关性系数

$$\rho_{xy}=\frac{c_{xy}}{\sigma_x\sigma_y}=\frac{r_{xy}-m_x m_y^*}{\sigma_x\sigma_y}, \qquad |\rho_{xy}|\le 1$$

Random variables 随机变量

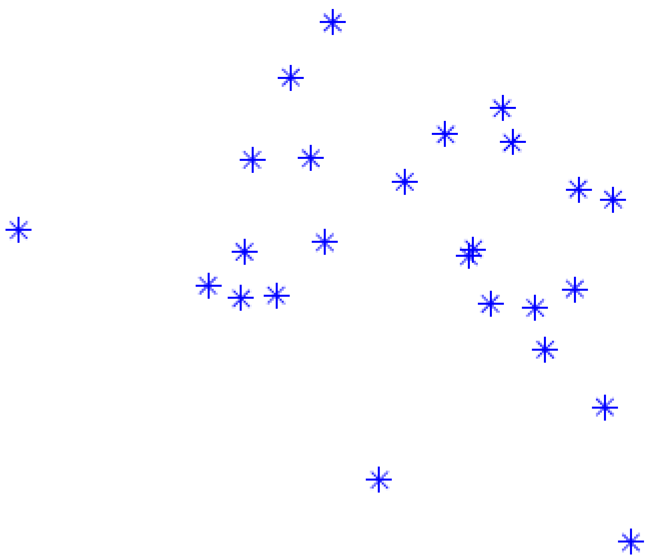

x and y uncorrelated

不相关

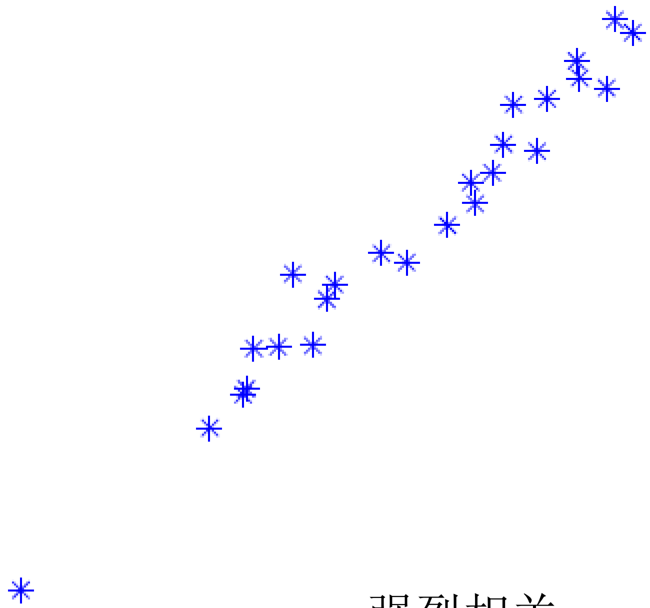

强烈相关

x and y strongly correlated

$y = \alpha x + n$ (small n)

Linearly dependent
线性依赖

DEFINITION 3.4 (WIDE-SENSE STATIONARITY). A random signal $x(n)$ is called *wide-sense stationary* (*WSS*) if

广义平稳

1. Its mean is a constant independent of n, that is, 均值是独立于n的常数

$$E\{x(n)\} = \mu_x$$

2. Its variance is also a constant independent of n, that is, 方差是独立于n的常数

$$\mathrm{var}[x(n)] = \sigma_x^2$$

and

3. Its autocorrelation depends only on the distance $l = n_1 - n_2$, called *lag*, that is,

$$r_x(n_1, n_2) = r_x(n_1 - n_2) = r_x(l) = E\{x(n+l)x^*(n)\} = E\{x(n)x^*(n-l)\}$$

自相关性仅仅依赖于距离l

随机变量

定义

- 两个随机变量x和y是独立的，如果

$$f_{x,y}(\alpha,\beta) = f_x(\alpha) f_y(\beta)$$

- 两个随机变量x和y不相关，如果：

$$E\{xy^*\} = E\{x\}E\{y^*\} \quad \text{or} \quad r_{xy} = m_x m_y^* \quad \text{or} \quad c_{xy} = 0$$

- 两个随机变量x和y是正交的：

$$r_{xy} = 0$$

- 正交随机变量不一定不相关
- 零均值不相关随机变量是正交的

随机过程

定义

- 随机过程x(n)是一个随机变量的索引序列(一个“信号”)
- 均值和方差:

$$m_x(n) = E\{x(n)\} \qquad \sigma_x^2(n) = E\{|x(n) - m_x(n)|^2\}$$

- 自相关和自协方差:

$$\begin{aligned} r_x(k,l) &= E\{x(k)x^*(l)\} \\ c_x(k,l) &= E\{[x(k)-m_x(k)][x(l)-m_x(l)]^*\} = r_x(k,l) - m_x(k)m_x^*(l) \end{aligned}$$

- 交叉相关和交叉协方差

$$\begin{aligned} r_{xy}(k,l) &= E\{x(k)y^*(l)\} \\ c_{xy}(k,l) &= E\{[x(k)-m_x(k)][y(l)-m_y(l)]^*\} = r_{xy}(k,l) - m_x(k)m_y^*(l) \end{aligned}$$

- 不相关和正交过程被定义为变量，但$\forall k, l$

随机过程

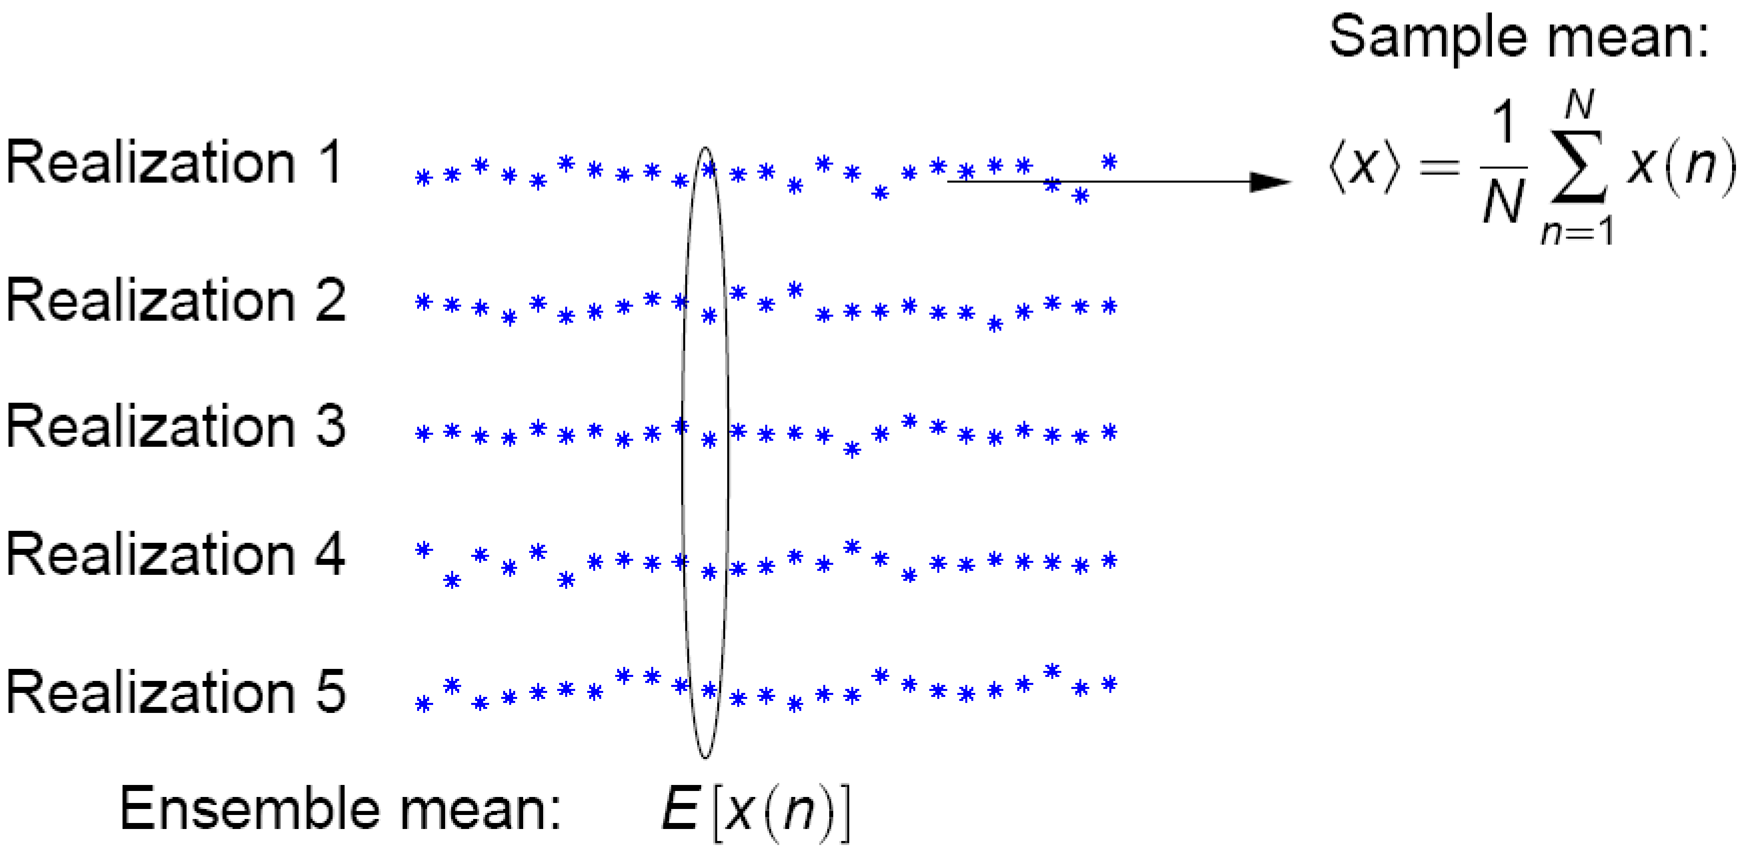

- **什么时候样本均值等于集合均值(期望)?**

随机过程

遍历性

- **样本均值:**

$$\hat{m}_x(N) = \frac{1}{N}\sum_{n=0}^{N-1} x(n)$$

- **WSS过程通常是遍历的，如果:**

$$\lim_{N\to\infty} E\{|\hat{m}_x(N) - m_x|^2\} = 0 \qquad \text{or} \qquad \lim_{N\to\infty} \hat{m}_x(N) = m_x$$

- **必要和充分条件:**

$$\lim_{N\to\infty} \frac{1}{N}\sum_{k=0}^{N-1} c_x(k) = 0$$

- **充分条件:**

$$\lim_{k\to\infty} c_x(k) = 0$$

- **对于高阶平均也存在类似的推导**

各态历经ergodic

$$m_x = E[x(n_1, n_2)] = \lim_{N\to\infty} \frac{1}{(2N+1)^2} \sum_{n_1=-N}^{N} \sum_{n_2=-N}^{N} x(n_1, n_2).$$

$$\begin{aligned} R_x(n_1, n_2) &= E[x(k_1, k_2)x^*(k_1 - n_1, k_2 - n_2)] \\ &= \lim_{N\to\infty} \frac{1}{(2N+1)^2} \sum_{k_1=-N}^{N} \sum_{k_2=-N}^{N} x(k_1, k_2)x^*(k_1 - n_1, k_2 - n_2) \end{aligned}$$

随机过程

功率谱

- **WSS过程的功率谱是自相关的DTFT:**

$$P_x(e^{j\omega}) = \sum_{k=-\infty}^{\infty} r_x(k) e^{-jk\omega}, \qquad \text{Also: } P_x(z) = \sum_{k=-\infty}^{\infty} r_x(k) z^{-k}$$

- **由于自相关是共轭对称的，所以功率谱是实数:**

$$P_x(z) = P_x^*(1/z^*) \qquad \Rightarrow \qquad P_x(e^{j\omega}) = P_x^*(e^{j\omega})$$

维纳滤波器非因果解推导（1/7）

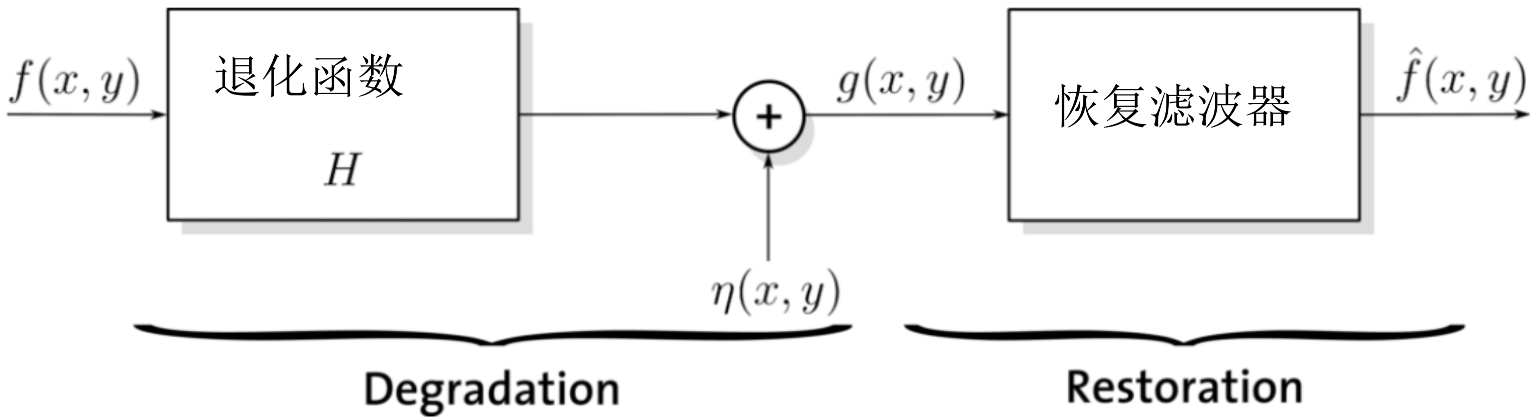

f(x,y): 0均值平稳随机过程，要估计的信号；
噪声：0均值平稳随机过程

如果H为线性的、位置不变的过程，则退化图像在空间域中由下式给出：

$$g(x,y) = h(x,y) * f(x,y) + \eta(x,y)$$

根据已退化图像g(x,y),
利用线性估计器估计原始图像

$$\boxed{\hat{f}(x,y) = w(x,y) * g(x,y)}$$

维纳滤波器非因果解推导（2/7）

先证：$g(x,y)=f(x,y)+\eta(x,y)$

最小化均方误差：$e^2(x,y)=E\left|e(x,y)\right|^2$

$e(x,y)=f(x,y)-\hat{f}(x,y)$

$\hat{f}(x,y)=w(x,y)*g(x,y)$

最小化均方误差可以由正交原则求解，
即：最优求解的误差与观测的信号值不相关

$$E[e(n_1,n_2)g^*(m_1,m_2)]=0$$

进一步分解得：

$$\mathrm{E}[\mathrm{f}(n_1,n_2)g^*(m_1,m_2)]=\mathrm{E}[\hat{\mathrm{f}}(n_1,n_2)g^*(m_1,m_2)]$$

$$=E[(w(n_1,n_2)*g(n_1,n_2))g^*(m_1,m_2)]$$

$$=\sum_{k_1=-\infty}^{\infty}\sum_{k_2=-\infty}^{\infty}w(k_1,k_2)E[g(n_1-k_1,n_2-k_2)g^*(m_1,m_2)]$$

维纳滤波器非因果解推导（3/7）

记：$\mathrm{R}_{fg}(n_1-m_1,n_2-m_2)$

$$=\sum_{k_1=-\infty}^{\infty}\sum_{k_2=-\infty}^{\infty} w(k_1,k_2)R_g(n_1-k_1-m_1,n_2-k_2-m_2)$$

其中：$R_g(n_1,n_2)=E[g(k_1,k_2)g^*(k_1-n_1,k_2-n_2)]$

所以：$\mathrm{R}_{fg}(n_1,n_2)=w(n_1,n_2)*R_g(n_1,n_2)$

两边取傅立叶变换得：

$$\mathrm{W}(\omega_1,\omega_2)=\frac{P_{fg}(\omega_1,\omega_2)}{P_g(\omega_1,\omega_2)}$$

非因果维纳滤波器

其中$P_{fg}(\omega_1,\omega_2)=\sum_{n_1}^{\infty}\sum_{n_2}^{\infty}R_{fg}(n_1,n_2)e^{-j(n_1\omega_1+n_2\omega_2)}$

是两个平稳随机过程的协功率谱

维纳滤波器非因果解推导（3/7）

因为：信号f与噪声η不相关：

$$\mathrm{E}[\mathrm{f}(n_1,n_2)\eta^*(m_1,m_2)]=\mathrm{E}[\mathrm{f}(n_1,n_2)]\mathrm{E}[\eta^*(m_1,m_2)]$$

进一步得：

$$\mathrm{R}_{\mathrm{fg}}(n_1,n_2)=\mathrm{R}_{\mathrm{f}}(n_1,n_2)$$

$$\mathrm{R}_{\mathrm{g}}(n_1,n_2)=\mathrm{R}_{\mathrm{f}}(n_1,n_2)+\mathrm{R}_{\eta}(n_1,n_2)$$

所以有：

$$P_{fg}(\omega_1,\omega_2)=P_{\mathrm{f}}(\omega_1,\omega_2)$$

$$P_{g}(\omega_1,\omega_2)=P_{\mathrm{f}}(\omega_1,\omega_2)+P_{\eta}(\omega_1,\omega_2)$$

所以非因果维纳滤波器脉冲响应为：

$$\mathrm{W}(\omega_1,\omega_2)=\frac{P_{\mathrm{f}}(\omega_1,\omega_2)}{P_{\mathrm{f}}(\omega_1,\omega_2)+P_{\eta}(\omega_1,\omega_2)}$$

维纳滤波器非因果解推导（4/7）

$$g(x,y)=h(x,y) * f(x,y)+\eta(x,y)$$

$$G(\omega_1,\omega_2)=H(\omega_1,\omega_2)F(\omega_1,\omega_2)+N(\omega_1,\omega_2)$$

另： $$\mathrm{Y}(\omega_1,\omega_2)=\frac{G(\omega_1,\omega_2)}{H(\omega_1,\omega_2)}=F(\omega_1,\omega_2)+\frac{N(\omega_1,\omega_2)}{H(\omega_1,\omega_2)}$$

$$f(n_1,n_2) \rightarrow \boxed{H(\omega_1,\omega_2)} \rightarrow \oplus \xrightarrow{g(n_1,n_2)} \underbrace{\boxed{\frac{1}{H(\omega_1,\omega_2)}} \xrightarrow{y(n_1,n_2)} \boxed{W(\omega_1,\omega_2)}}_{W'(\omega_1,\omega_2)} \rightarrow \hat{f}(n_1,n_2)$$

$$\uparrow$$

$$\eta(n_1,n_2)$$

维纳滤波器非因果解推导（5/7）

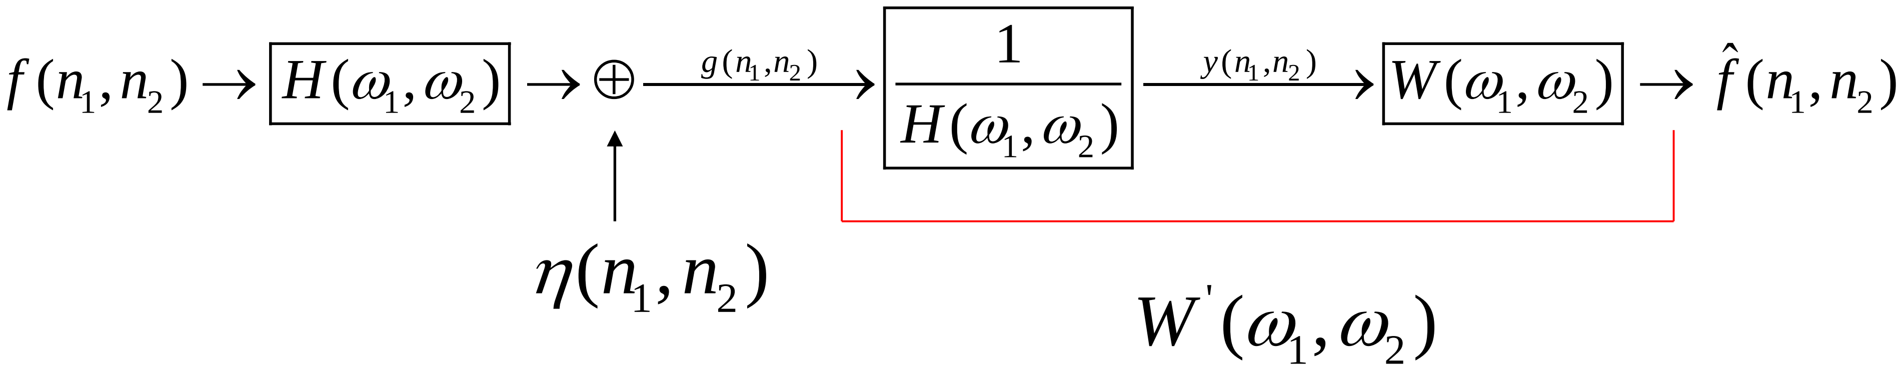

$$
\begin{aligned}
\hat{F}(\omega_1,\omega_2) &= W(\omega_1,\omega_2)Y(\omega_1,\omega_2) \\
&= W(\omega_1,\omega_2)\frac{G(\omega_1,\omega_2)}{H(\omega_1,\omega_2)} \\
&= \frac{W(\omega_1,\omega_2)}{H(\omega_1,\omega_2)}G(\omega_1,\omega_2) \\
&= W'(\omega_1,\omega_2)G(\omega_1,\omega_2)
\end{aligned}
$$

维纳滤波器非因果解推导（6/7）

$$f(n_1,n_2)\rightarrow\boxed{H(\omega_1,\omega_2)}\rightarrow\bigoplus\xrightarrow{g(n_1,n_2)}\underbrace{\boxed{\frac{1}{H(\omega_1,\omega_2)}}\xrightarrow{y(n_1,n_2)}\boxed{W(\omega_1,\omega_2)}}_{W'(\omega_1,\omega_2)}\rightarrow\hat{f}(n_1,n_2)$$

$$\uparrow$$

$$\eta(n_1,n_2)$$

$$W'(\omega_1,\omega_2)=\frac{1}{H(\omega_1,\omega_2)}\frac{P_f(\omega_1,\omega_2)}{P_f(\omega_1,\omega_2)+P_N(\omega_1,\omega_2)}$$

$$=\frac{1}{H(\omega_1,\omega_2)}\frac{\left|F(\omega_1,\omega_2)\right|^2}{\left|F(\omega_1,\omega_2)\right|^2+\left|\dfrac{N(\omega_1,\omega_2)}{H(\omega_1,\omega_2)}\right|^2}$$

$$=\frac{H^*(\omega_1,\omega_2)\left|F(\omega_1,\omega_2)\right|^2}{\left|H(\omega_1,\omega_2)\right|^2\left|F(\omega_1,\omega_2)\right|^2+\left|N(\omega_1,\omega_2)\right|^2}$$

功率谱

$$r_f(x,y)=\int_{-\infty}^{\infty}\int_{-\infty}^{\infty} f(a,b)\cdot f(x+a,y+b)\,da\,db$$

傅里叶域中的自相关函数:

$$\Im\left[r_f(x,y)\right]=F^*(u,v)F(u,v)=\left|F(u,v)\right|^2=S_F(u,v)$$

自相关函数和功率谱是一个傅里叶对:

$$S_F(u,v)=\int_{-\infty}^{\infty} r_f(x,y)\,e^{-j2\pi(xu+yv)}\,dx\,dy$$

自相关、功率谱和随机信号(不含噪声)

这对于随机信号是有效的:

$$r_n(x,y)=E\{n(a,b)\cdot n(x+a,y+b)\}$$

White noise:

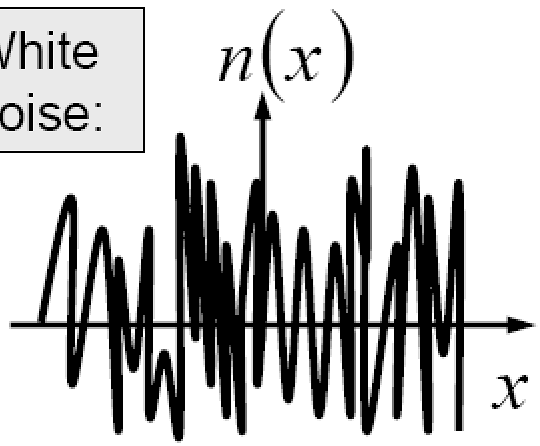

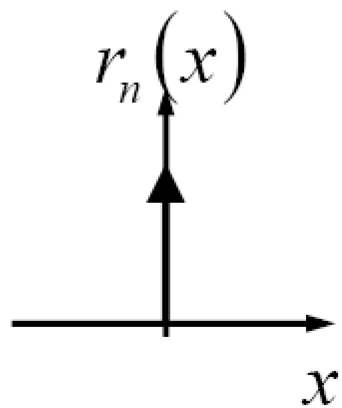

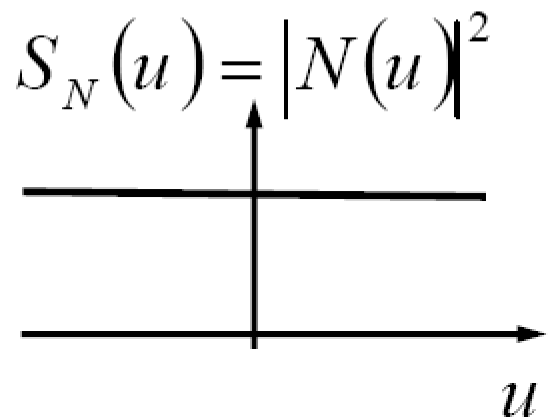

利用自相关函数和功率谱，我们可以用噪声进行计算!

最小均方误差（Wiener）滤波

误差函数的最小值在频域由表达式给出

$$\hat{F}(u,v)=\left[\frac{H^*(u,v)S_f(u,v)}{S_f(u,v)|H(u,v)|^2+S_\eta(u,v)}\right]G(u,v)$$

$$=\left[\frac{H^*(u,v)}{|H(u,v)|^2+S_\eta(u,v)/S_f(u,v)}\right]G(u,v)$$

$$=\left[\frac{1}{H(u,v)}\frac{|H(u,v)|^2}{|H(u,v)|^2+S_\eta(u,v)/S_f(u,v)}\right]G(u,v)$$

最小均方误差（Wiener）滤波

$$\hat{F}(u,v)=\left[\frac{1}{H(u,v)}\frac{|H(u,v)|^2}{|H(u,v)|^2+S_\eta(u,v)/S_f(u,v)}\right]G(u,v)$$

$H(u,v)$: 退化函数

$H^*(u,v)$: H(u,v)的复共轭

$|H(u,v)|^2=H^*(u,v)H(u,v)$

$S_\eta(u,v)=|N(u,v)|^2=$ 噪声的功率谱

$S_f(u,v)=|F(u,v)|^2=$ 未退化图像的功率谱

Wiener filter维纳滤波器(1/6)

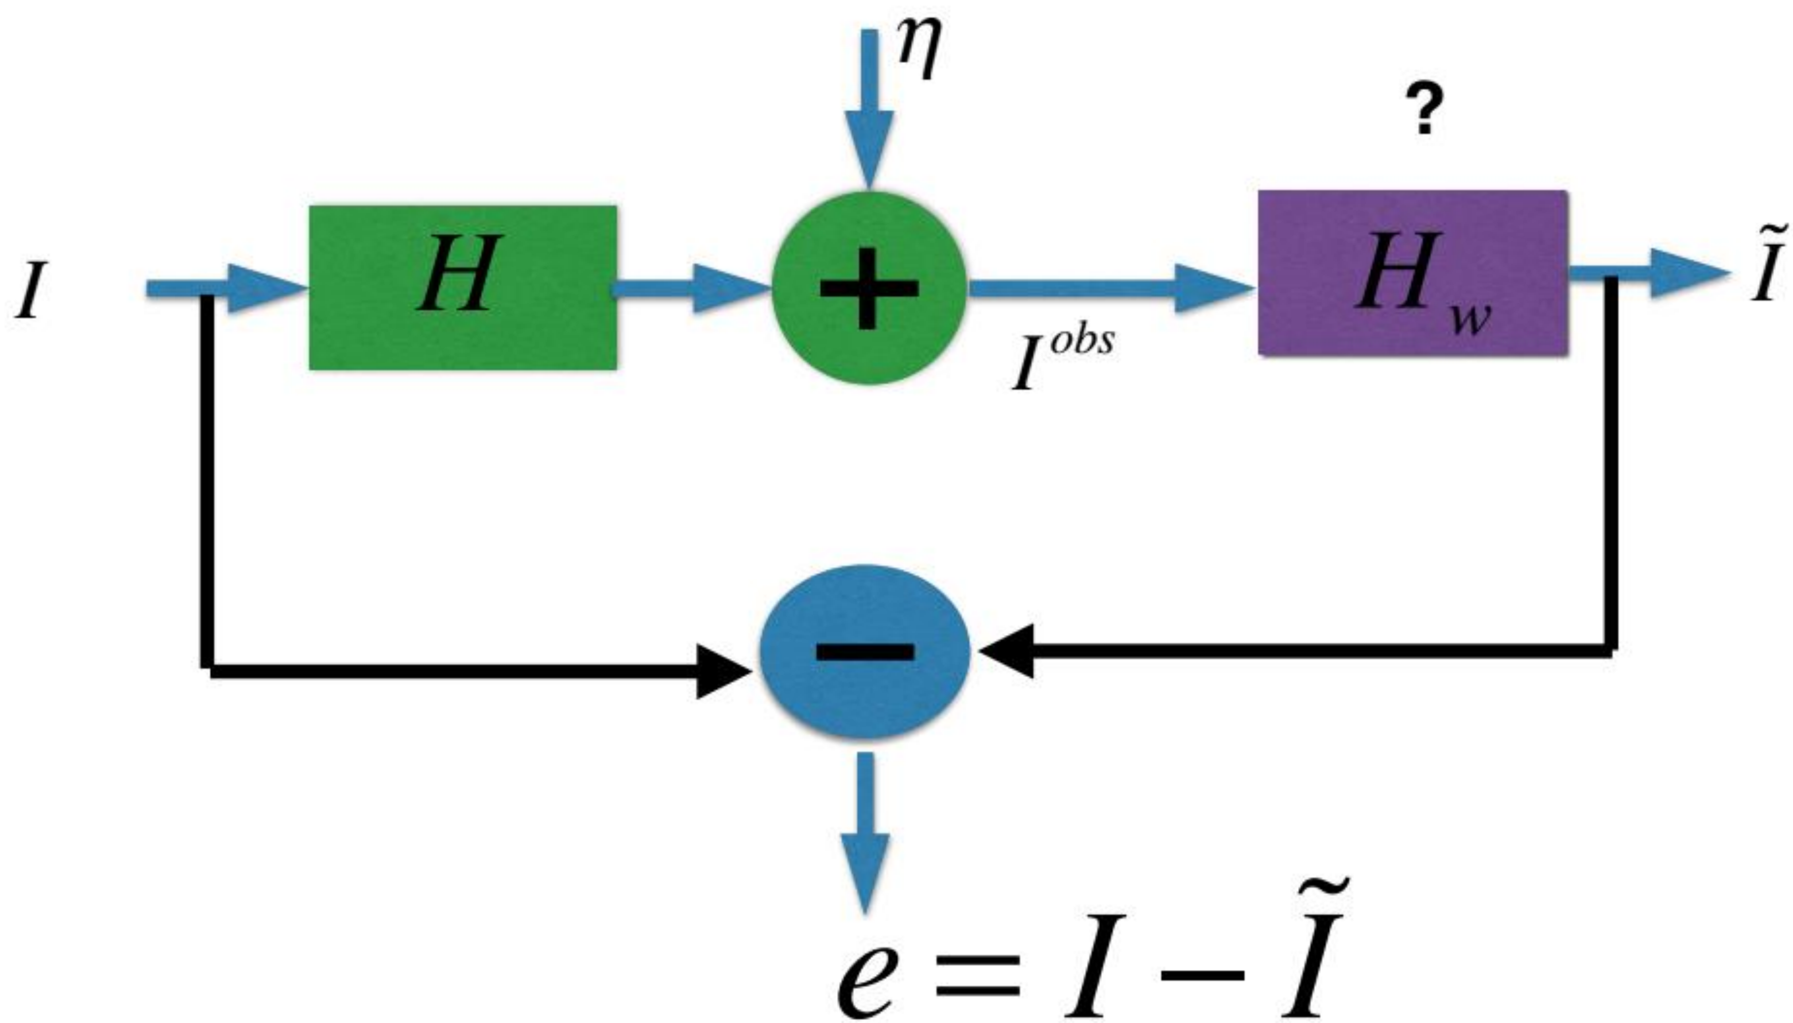

Wiener filter维纳滤波器(2/6)

- 假设:
  - I和η都是二维平稳随机序列
  - I和η彼此不相关
  - 已知图像I和噪声η的功率谱

$$E\left\{\left\|\hat{I}(u)\right\|_2^2\right\}=E\left\{\hat{I}^*(u)\hat{I}(u)\right\}=S_I(u)$$

$$E\left\{\left\|\hat{\eta}(u)\right\|_2^2\right\}=E\left\{\hat{\eta}^*(u)\hat{\eta}(u)\right\}=S_\eta(u)$$

$$E\left\{\hat{I}^*(u)\hat{\eta}(u)\right\}=E\left\{\hat{I}(u)\hat{\eta}^*(u)\right\}=0$$

$$\hat{I}=DFT(I)$$

$\hat{I}^*(u)$: the complex conjugate of $\hat{I}(u)$

Wiener filter维纳滤波器(3/6)

- **对象函数(MMSE)**
  最小均方误差滤波器(统计方法)

Parseval's theorem

$$J\left(H_w\right)=E\left\{\left\|I-H_w * I^{obs}\right\|_2^2\right\} \quad \text{(空间域)}$$

$$J\left(\hat{H}_w\right)=E\left\{\left\|\hat{I}-\hat{H}_w \cdot \hat{I}^{obs}\right\|_2^2\right\} \quad \text{(频域)}$$

$$\boxed{\min_{H_w} J\left(H_w\right) \equiv \min_{\hat{H}_w} J\left(\hat{H}_w\right)}$$

维纳滤波(4/6)

- **Object function in Discrete Frequency Domain**

离散频域中的对象函数

$$J\left(\hat{H}_w\right)=\sum_u J\left(\hat{H}_w(u)\right)$$

$$J\left(\hat{H}_w(u)\right)=E\left\{\left\|\hat{I}(u)-\hat{H}_w(u)\cdot\hat{I}^{obs}(u)\right\|_2^2\right\}$$

$$=S_I(u)+\left\|\hat{H}_w(u)\right\|_2^2\cdot\left(\left\|\hat{H}(u)\right\|_2^2\cdot S_I(u)+S_\eta(u)\right)$$

$$-\hat{H}_w(u)\cdot\hat{H}(u)\cdot S_I(u)-\hat{H}_w^*(u)H^*(u)S_I(u)$$

Wiener filter

Let $\dfrac{\partial J\left(\hat{H}_w\right)}{\partial\hat{H}_w(u)}=0 \Rightarrow \boxed{\hat{H}_w(u)=\dfrac{\hat{H}^*(u)S_I(u)}{\left\|\hat{H}(u)\right\|_2^2 S_I(u)+S_\eta(u)}}$

维纳滤波(5/6)

- **Wiener filtering**

$$\hat{\tilde{I}}(u)=\hat{H}_w(u)\hat{I}^{obs}(u)=\frac{1}{\hat{H}(u)}\frac{\left\|\hat{H}(u)\right\|_2^2}{\left\|\hat{H}(u)\right\|_2^2+\frac{S_\eta(u)}{S_I(u)}}\cdot\hat{I}^{obs}(u)$$

很难估计未被降解的图像或噪声的功率谱

Hard to estimate the power spectrum of either the un-degraded image or the noise

- **White noise, unknown** $S_I(u)$

$$\hat{\tilde{I}}(u)=\hat{H}_w(u)\hat{I}^{obs}(u)=\frac{1}{\hat{H}(u)}\frac{\left\|\hat{H}(u)\right\|_2^2}{\left\|\hat{H}(u)\right\|_2^2+K}\cdot\hat{I}^{obs}(u)$$

维纳滤波(6/6)

- **Wiener Filter Special Cases**

$$\hat{H}_w(u) = \frac{\hat{H}^*(u)S_I(u)}{\left\|\hat{H}(u)\right\|_2^2 S_I(u) + S_\eta(u)}$$

✦ Denoising: No Blur (H=1)

$$\hat{H}_w(u) = \frac{S_I(u)}{S_I(u) + S_\eta(u)} = \frac{1}{1 + {S_\eta(u)}/{S_I(u)}}$$

✦ Denoising: No Noise ($S_\eta = 0$)

$$\hat{H}_w(u) = \frac{\hat{H}^*(u)}{\left\|\hat{H}(u)\right\|_2^2} = \frac{1}{\hat{H}(u)}$$

Inverse Filter

评价指标(1)

Singal-to-Noise Ratio (SNR)

$$SNR = \frac{\sum_{u=0}^{M-1}\sum_{v=0}^{N-1}|F(u,v)|^2}{\sum_{u=0}^{M-1}\sum_{v=0}^{N-1}|N(u,v)|^2}$$

This ratio gives a measure of the level of information bearing singal power to the level of noise power.

这个比率给出了一个衡量含信息的单数功率水平与噪声功率水平的标准。

评价指标(2)

Mean Square Error (MSE)

$$\text{MSE}=\frac{1}{MN}\sum_{x=0}^{M-1}\sum_{y=0}^{N-1}\left[f(x,y)-\hat{f}(x,y)\right]^2$$

Root-Mean-Sqaure-Error (RMSE)

$$\text{RMSE}=\frac{\sum_{u=0}^{M-1}\sum_{v=0}^{N-1}\hat{f}(x,y)^2}{\sum_{u=0}^{M-1}\sum_{v=0}^{N-1}|f(x,y)-\hat{f}(x,y)|^2}$$

Example) frequency response for two Wiener filters 两个维纳滤波器的频率响应

$$H(u,v) = \mathrm{sinc}(ku) \cdot \mathrm{sinc}(kv)$$

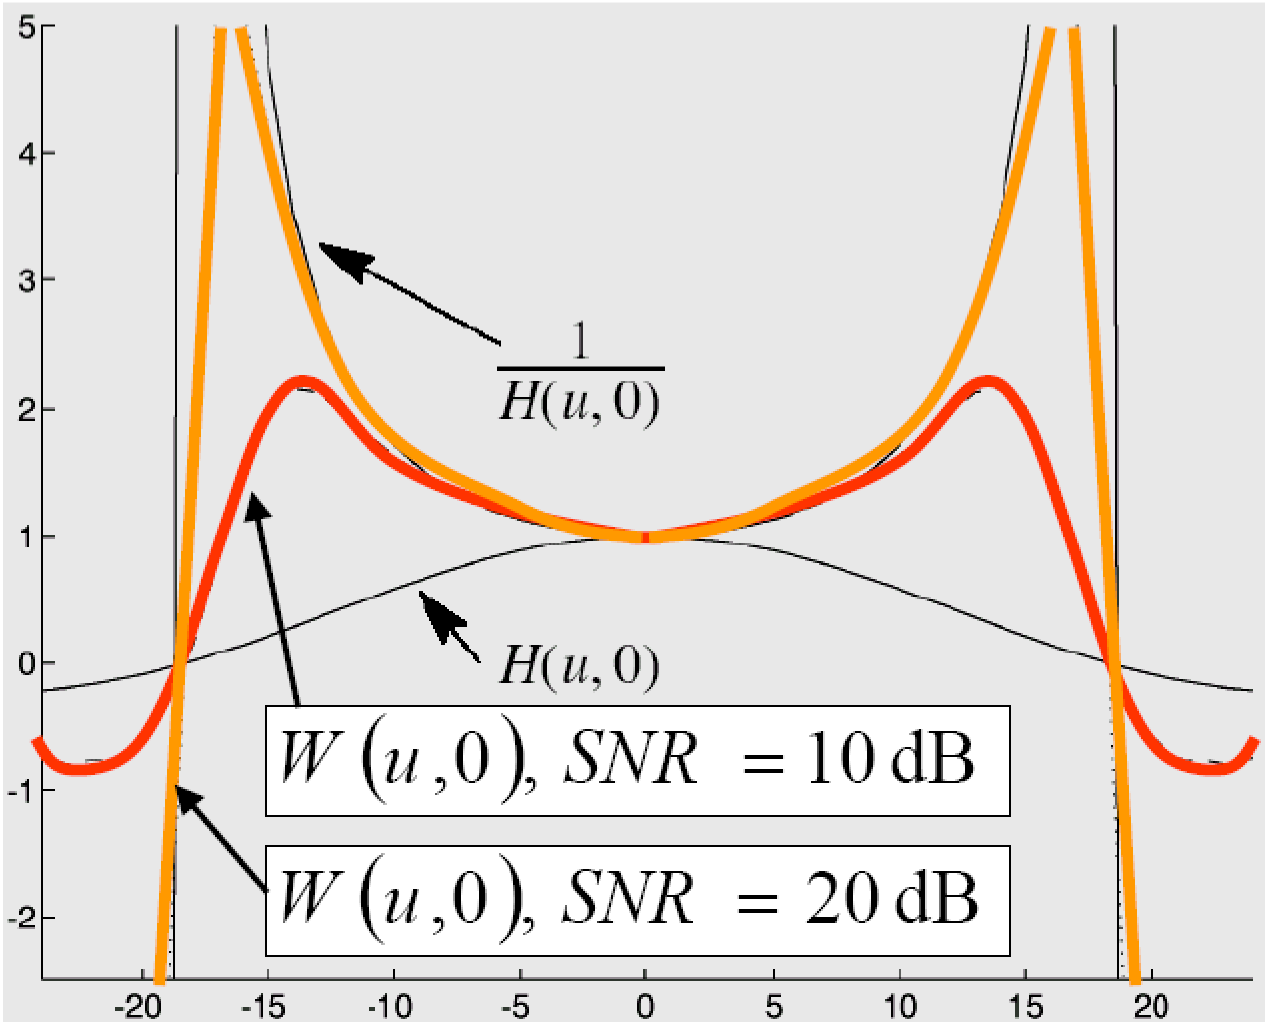

为了能够进行维纳滤波，我们需要知道什么？

What do we need to know to be able to perform Wiener filtering?

噪声的自相关函数

- The autocorrelation function of the noise, $r_n(x,y)$
  - Ex) $r_n(x,y)=\sigma_n^2\,\delta(x,y)$ for white noise with variance σ_n^2

图像的自相关函数

- The autocorrelation function of the image, $r_f(x,y)$
  - Ex) $$r_f(x,y)=\sigma_f^2\,\rho^{\sqrt{x^2+y^2}}$$

退化函数

- The degradation function $h(x,y)$
  - Ex) the Gauss-like function that models atmospheric turbulence

$$\hat{F}(u,v)=\left[\frac{1}{H(u,v)}\frac{|H(u,v)|^2}{|H(u,v)|^2+S_\eta(u,v)/S_f(u,v)}\right]G(u,v)$$

The autocorrelation function of the noise, $r_n(x,y)$ 噪声的自相关函数 $r_n(x,y)$

噪声可在此测量，假设噪声是白噪声则有 $r_n(x,y)=\sigma_n^2\delta(x,y)$，方差 σ_n^2 可以在边长为N的正方形计算得出

- The noise can be measured here. Suppose that the noise is white so that $r_n(x,y)=\sigma_n^2\delta(x,y)$. The variance σ_n^2 can be calculated here in the square η of size N^2:

$$\sigma_n^2 = \frac{\sum_{x,y\in\eta}(f(x,y)-\mu)^2}{N^2} \quad \approx(5.2\text{-}16)$$

where

$$\mu = \frac{\sum_{x,y\in\eta} f(x,y)}{N^2} \quad \approx(5.2\text{-}15)$$

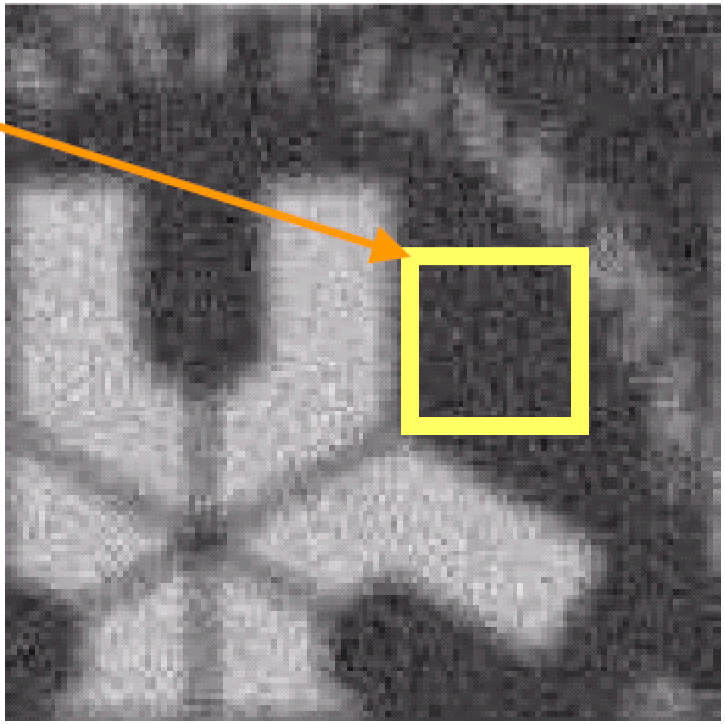

The autocorrelation function of the image, $r_f(x,y)$

$$r_f(x,y)=\sum_a\sum_b f(a,b)\cdot f(x+a,y+b)$$

$$r_f(x,y)\le\|f(x,y)\|\cdot\|f(x,y)\|=\sum_a\sum_b f^2(a,b)$$

- The autocorrelation function is always maximal in the point $(x,y)=(0,0)$. This is valid for all images.
- The autocorrelation function is always symmetrical, i.e. $r_f(x,y)=r_f(-x,-y)$

The autocorrelation function of the image, $r_f(x,y)$ 图像的自相关函数 $r_f(x,y)$

- This model is good for natural images: 这个模型适合于自然图像

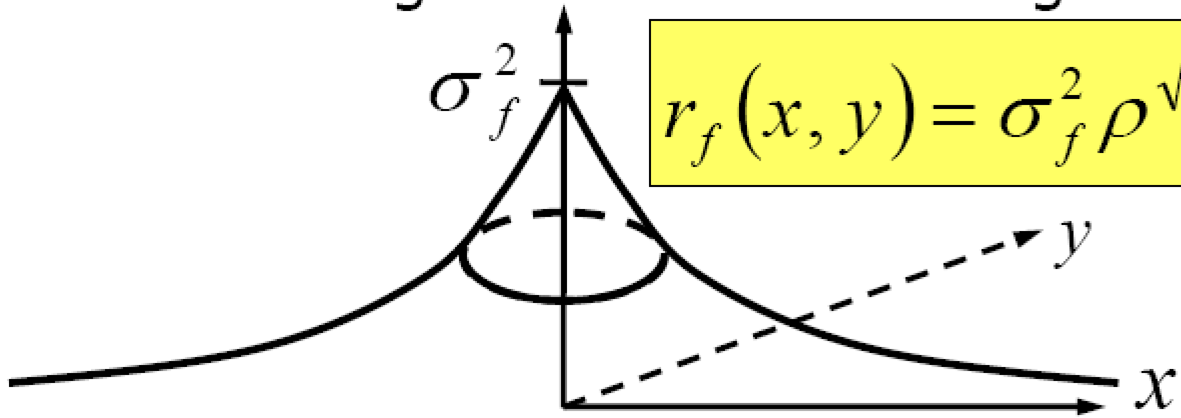

$$r_f(x,y) = \sigma_f^2 \rho^{\sqrt{x^2+y^2}}$$

- It is supposed that images of the same type, for example faces or license plates, have the same ρ

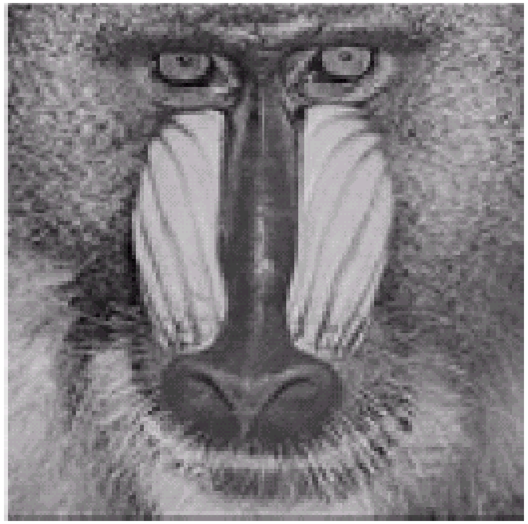

相同类型的图像，例如人脸或车牌，具有相同的 ρ 值。

The autocorrelation function of one image, $r_f(x,y)$ 一幅图像的自相关函数 $r_f(x,y)$

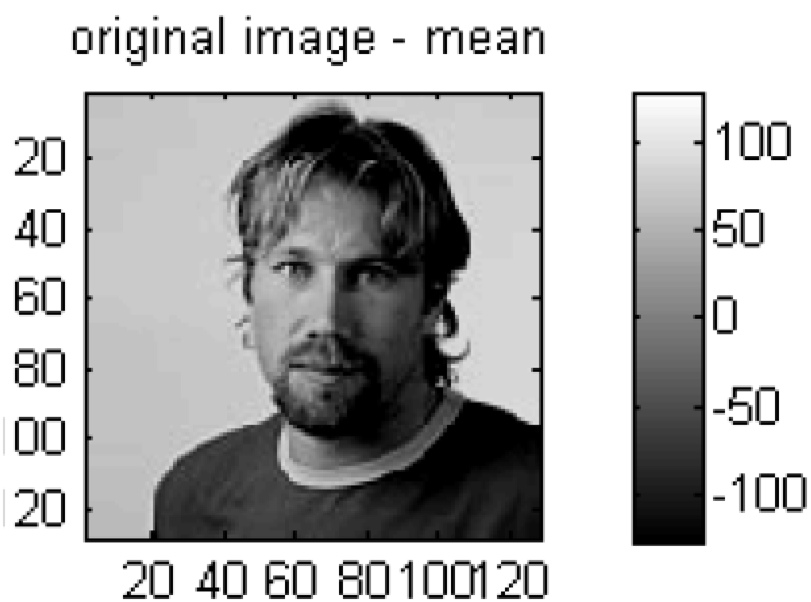

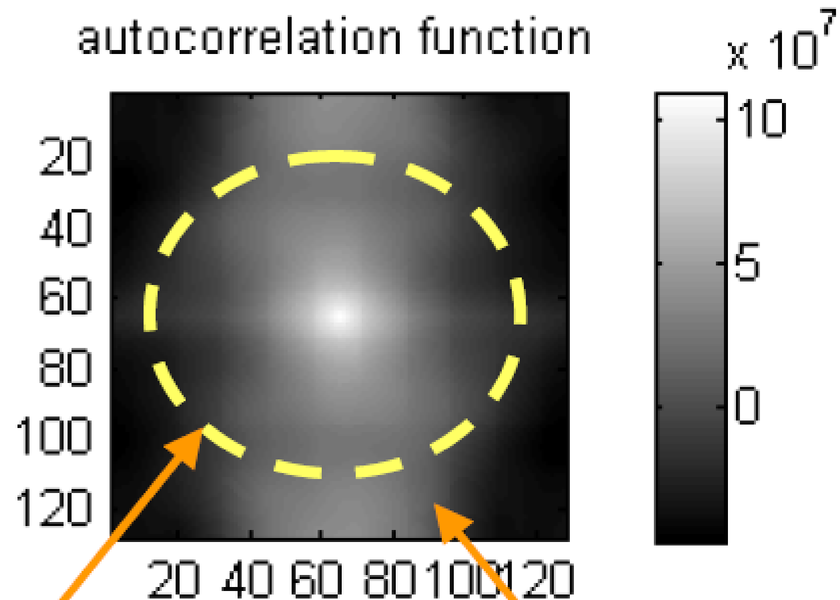

$$r_f(x,y) \approx \sigma_f^2 \rho^{\sqrt{x^2+y^2}}$$

Circular convolution effects in the outer area of the image because the computation was performed in the Fourier domain.

由于计算是在傅里叶域进行的，所以图像的外部区域存在循环卷积效应。

CALCULATION OF THE ACF　ACF的计算

Since a correlation (convolution) in object space "reduces" to a multiplication in frequency space, Fourier transforms may be used: the product of the Fourier transform of an image times its complex conjugate is the Fourier transform of the ACF. The most efficient way of calculating Fourier transforms is to use FFT methods.

由于物体空间的相关（卷积）"还原 "为频率空间的乘法，因此可以使用傅里叶变换：图像的傅里叶变换乘以其复共轭的乘积就是ACF的傅里叶变换，计算傅里叶变换的最有效方法是使用FFT方法

image (object space)　　FFT (frequency space)　　ACF (object space)

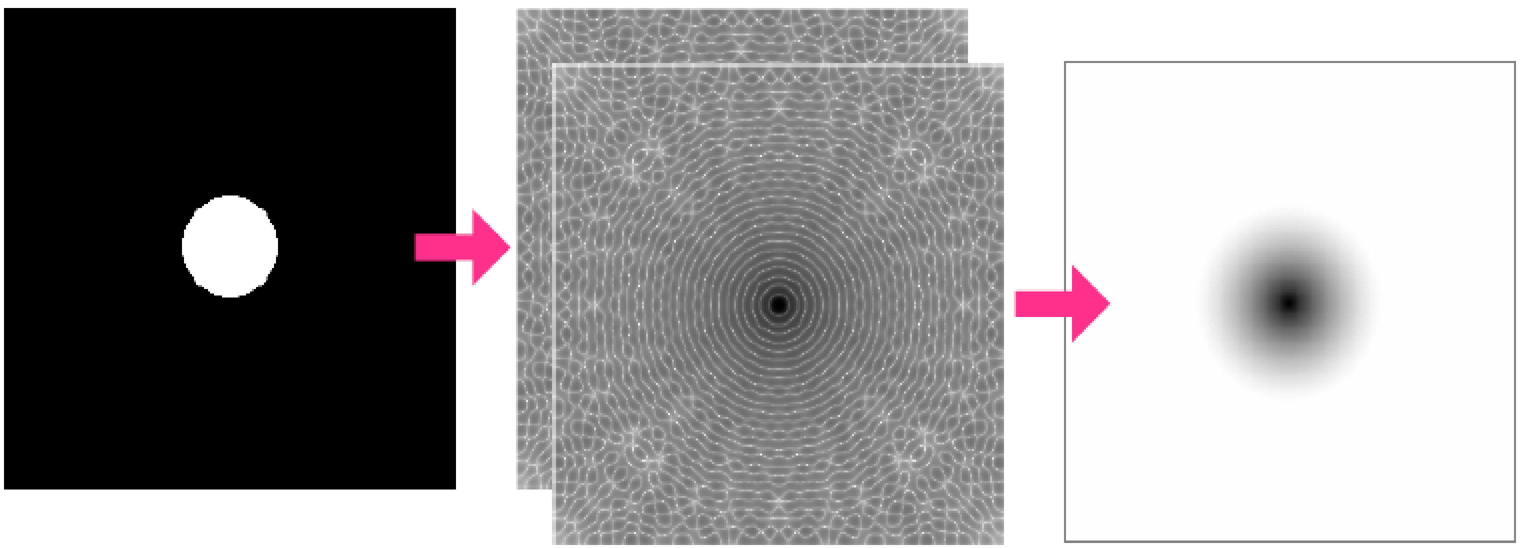

$$F^*(u,v)F(u,v)$$

最小均方误差（维纳）滤波

$$F(u,v)=\left[\frac{1}{H(u,v)}\frac{|H(u,v)|^2}{|H(u,v)|^2+K}\right]G(u,v)$$

K is a specified constant. Generally, the value of K is chosen interactively to yield the best visual results.

K是一个指定的常数。一般来说，K的值是以交互方式选择的，以产生最佳的视觉效果。

最小均方误差（维纳）滤波

a b c

FIGURE 5.28 Comparison of inverse and Wiener filtering. (a) Result of full inverse filtering of Fig. 5.25(b). (b) Radially limited inverse filter result. (c) Wiener filter result.

Left:
退化图像
Middle:
反滤波
Right:
维纳滤波

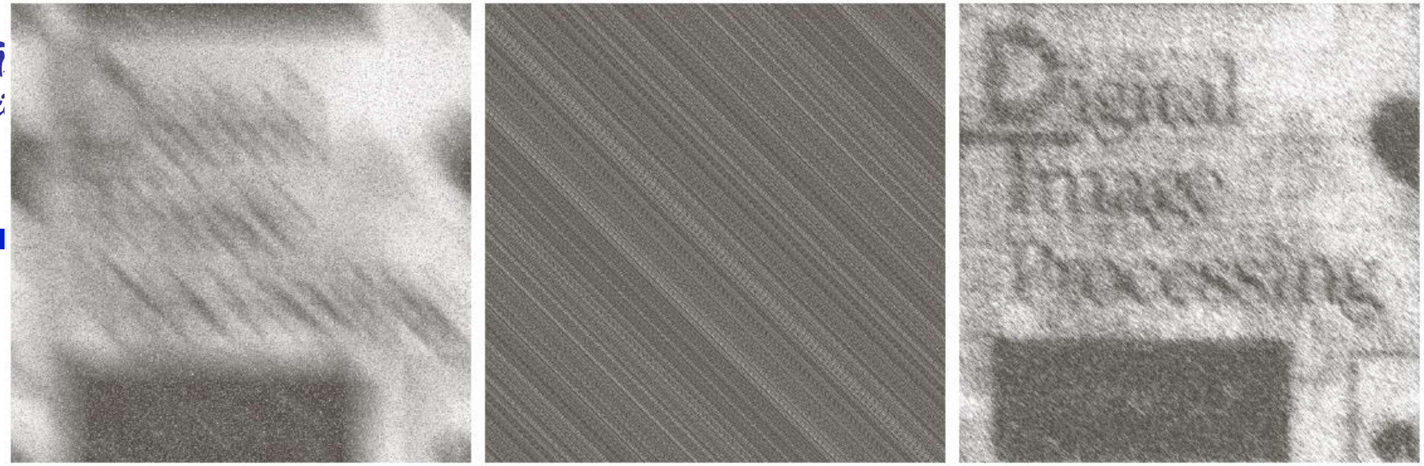

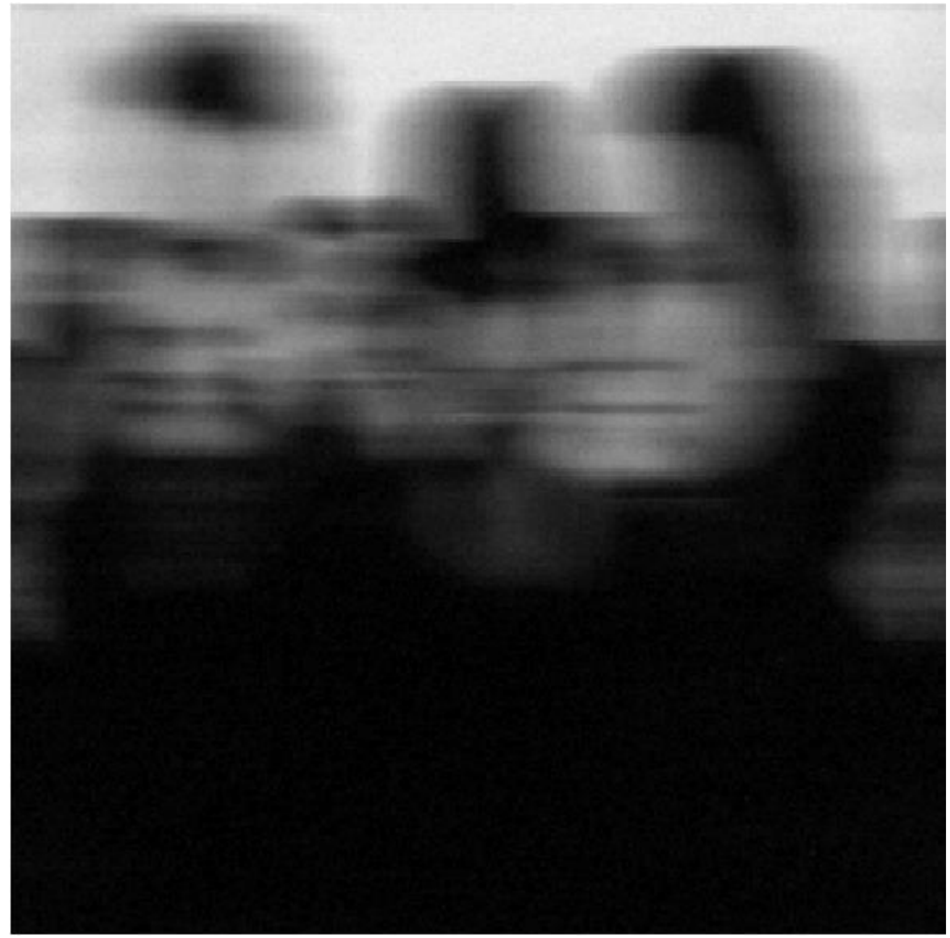

由于运动和噪音的影响，有些模糊不清

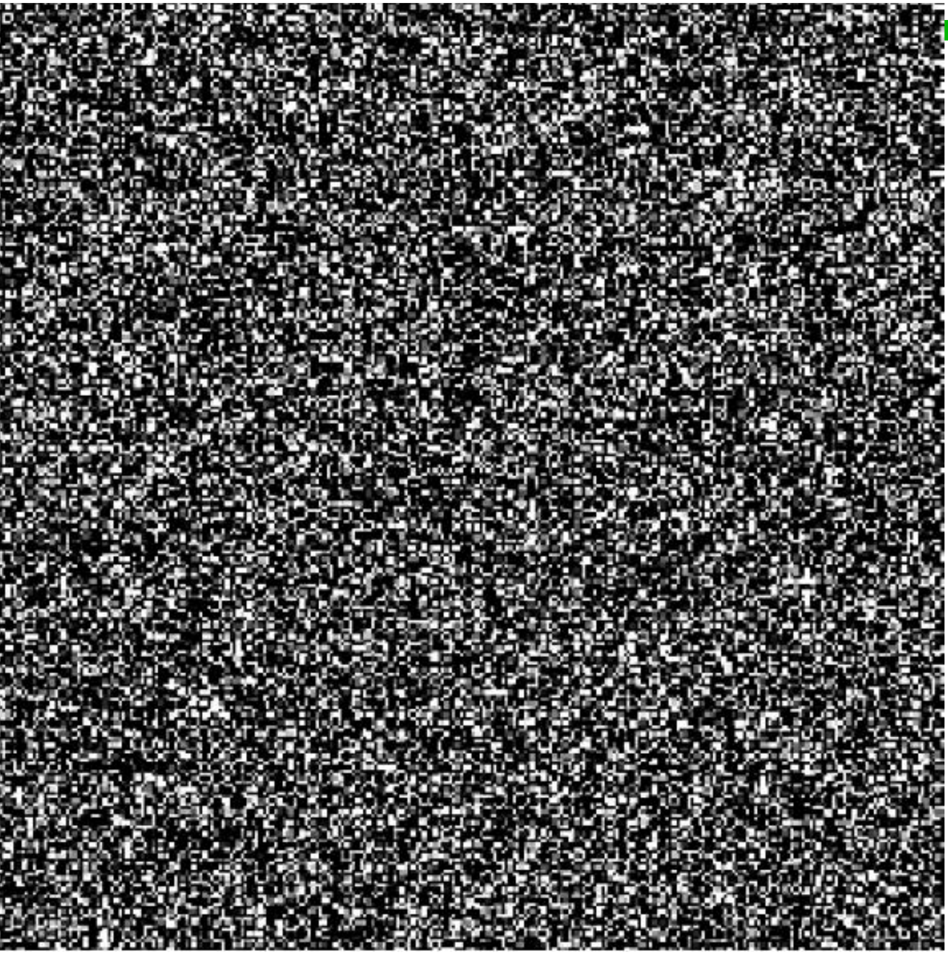

随机高斯噪音（这里乘以100的系数）被添加到照片的模糊版本中。

通过维纳滤波重建的照片

Content

- 退化-恢复模型
- 噪声模型
- 空域滤波器恢复
- 频域滤波恢复
- 线性位置不变退化
- 退化函数估计
- 逆滤波器
- 维纳滤波器-最小均方误差
- 约束最少二乘滤波器
- 几何均值滤波器

约束最少二乘滤波器

问题：
必须知道图像和噪声的功率谱。更难的是估计图像的功率谱或估计K（功率谱比）。

Problem:

- the power spectrum of image and noise must be known
- More difficult is to estimate the power spectrum of the image
- or estimate K (the power spectrum ratio)

给出噪声的均值和方差

Given the mean and variance of the noise

↓

How to get optimum filtering ?

怎么得到最优过滤器

受限最小二乘法过滤

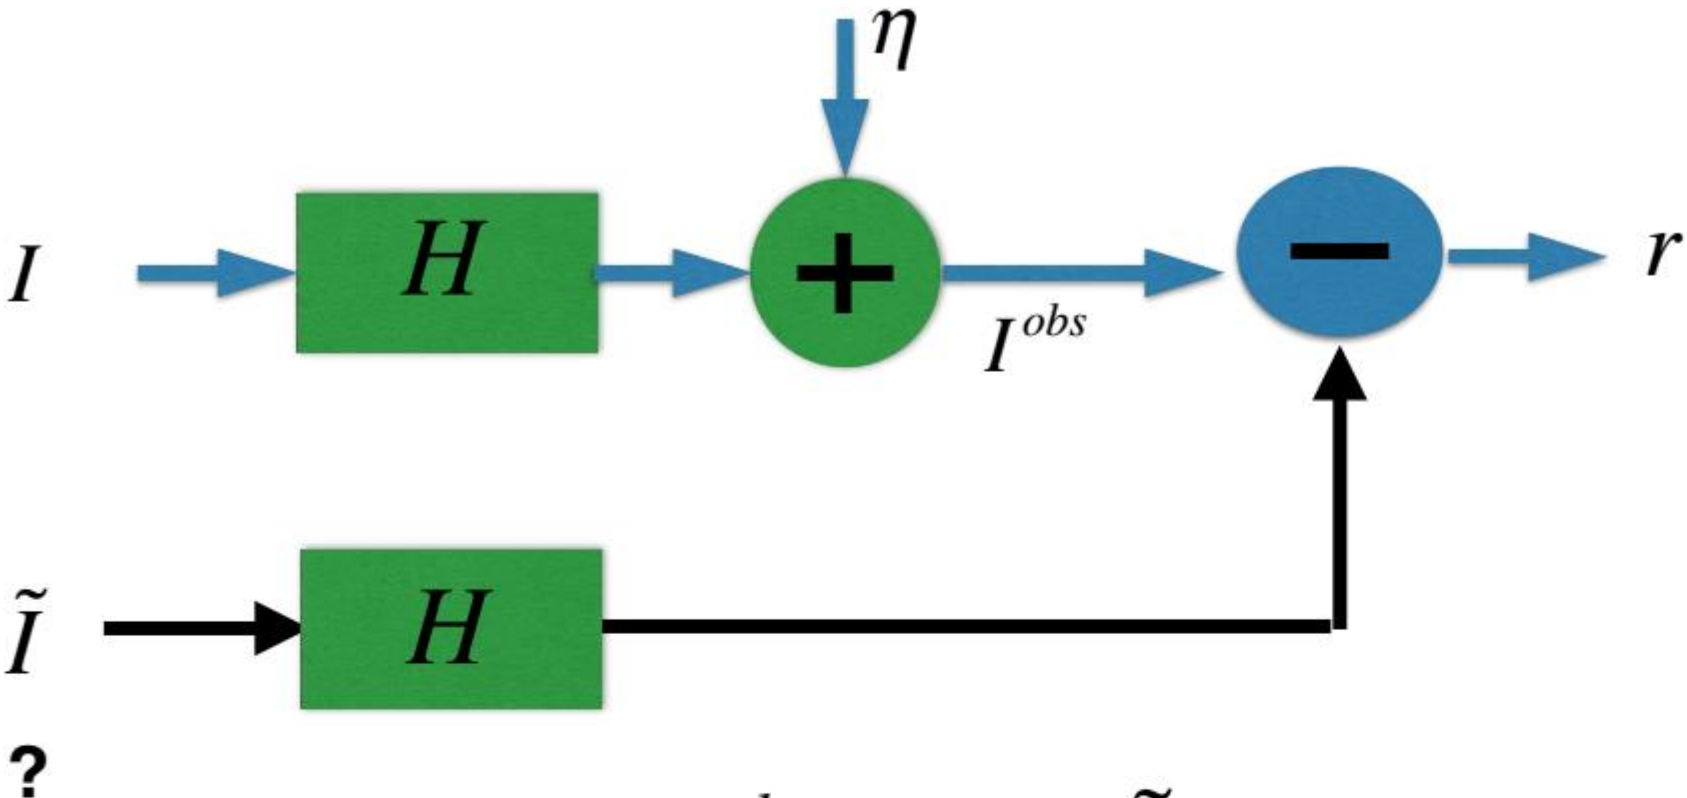

$$r = I^{obs} - H * \tilde{I}$$

直接从观察图像中恢复图像

受限最小二乘法过滤

- **在维纳滤波中，必须知道未退化的图像和噪声的功率谱。尽管常数估计有时是有用的，但它并不总是适合。**

- **受限最小二乘法滤波只需要噪声的平均值和方差。**

$$\text{最小化}\quad : \quad C=\sum_{x=0}^{M-1}\sum_{y=0}^{N-1}[\nabla^2 \hat{f}(x,y)]^2$$

$$\text{约束}\quad : \left\| g - H\hat{f} \right\|^2 = \left\| \eta \right\|^2$$

$\left\| w \right\|^2 = w^T w;\ \hat{f}$ **未退化图像的估计图像**

频域法证明

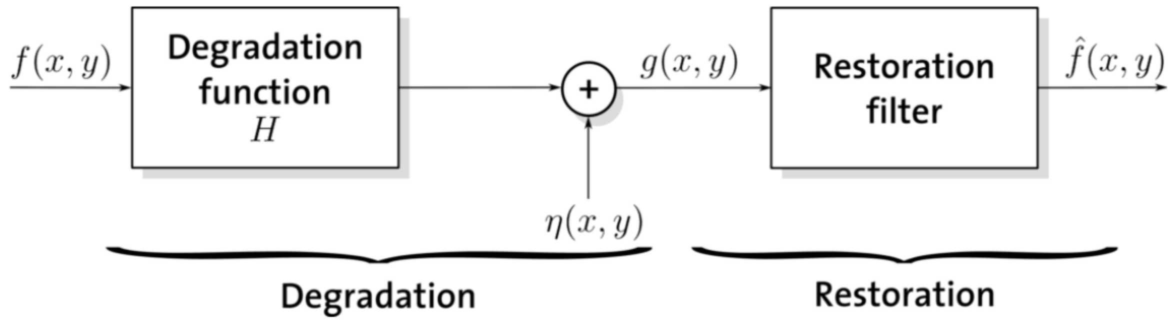

$$g(x,y)=\sum_{k=0}^{M-1}\sum_{l=0}^{N-1} f(k,l)h(x-k,y-l)+\eta(x,y)$$

如果考虑平滑图像即除噪, 可选用拉普拉斯算子, 则最小化:

$$\sum_{x=0}^{M-1}\sum_{y=0}^{N-1}[c(x,y)*\hat{f}(x,y)]^2$$

约束为:

$$v^2=\sum_{x=0}^{M-1}\sum_{y=0}^{N-1}\eta^2(x,y)$$

频域法证明

帕斯瓦定理：

$$\sum_{x=0}^{M-1}\sum_{y=0}^{N-1}|f(x,y)|^2=\frac{1}{\mathrm{MN}}\sum_{u=0}^{M-1}\sum_{v=0}^{N-1}|\mathrm{F(u,v)}|^2$$

利用*DFT*和帕斯瓦定理得：

$$\mathrm{G(u,\ v)=H(u,\ v)\hat{F}(u,\ v)+N(u,\ v)}$$

$$\mathrm{V}^2=\frac{1}{\mathrm{MN}}\sum_{u=0}^{M-1}\sum_{v=0}^{N-1}|\mathrm{N(u,v)}|^2$$

则优化问题为：最小化：

$$\frac{1}{\mathrm{MN}}\sum_{u=0}^{M-1}\sum_{v=0}^{N-1}\left|\mathrm{C(u,v)\hat{F}(u,v)}\right|^2$$

约束为：

$$\frac{1}{\mathrm{MN}}\sum_{u=0}^{M-1}\sum_{v=0}^{N-1}\left|\mathrm{G(u,v)\text{-}H(u,v)\hat{F}(u,v)}\right|^2=\mathrm{V}^2$$

频域法证明

则利用拉格朗日乘子法得：

目标函数：$J=\frac{1}{MN}\sum_{u=0}^{M-1}\sum_{v=0}^{N-1}\{\left|C(u,v)\hat{F}(u,v)\right|^2+\lambda(\left|G(u,v)-H(u,v)\hat{F}(u,v)\right|^2-V^2)\}$

因为$\hat{F}(u,v)=A(u,v)+jB(u,v)$,

分别对实部和虚部求偏导得：

$$\frac{\partial J}{\partial A}=2|C|^2A+2\lambda|H|^2A-\lambda(GH^*+G^*H)$$

$$\frac{\partial J}{\partial B}=2|C|^2B+2\lambda|H|^2B+j\lambda(GH^*-G^*H)$$

令上式等于0得：

$$\hat{F}(u,v)=\frac{H^*(u,v)}{|H(u,v)|^2+\frac{1}{\lambda}|C|^2}G(u,v)$$

受限最小二乘法过滤 (1/6)

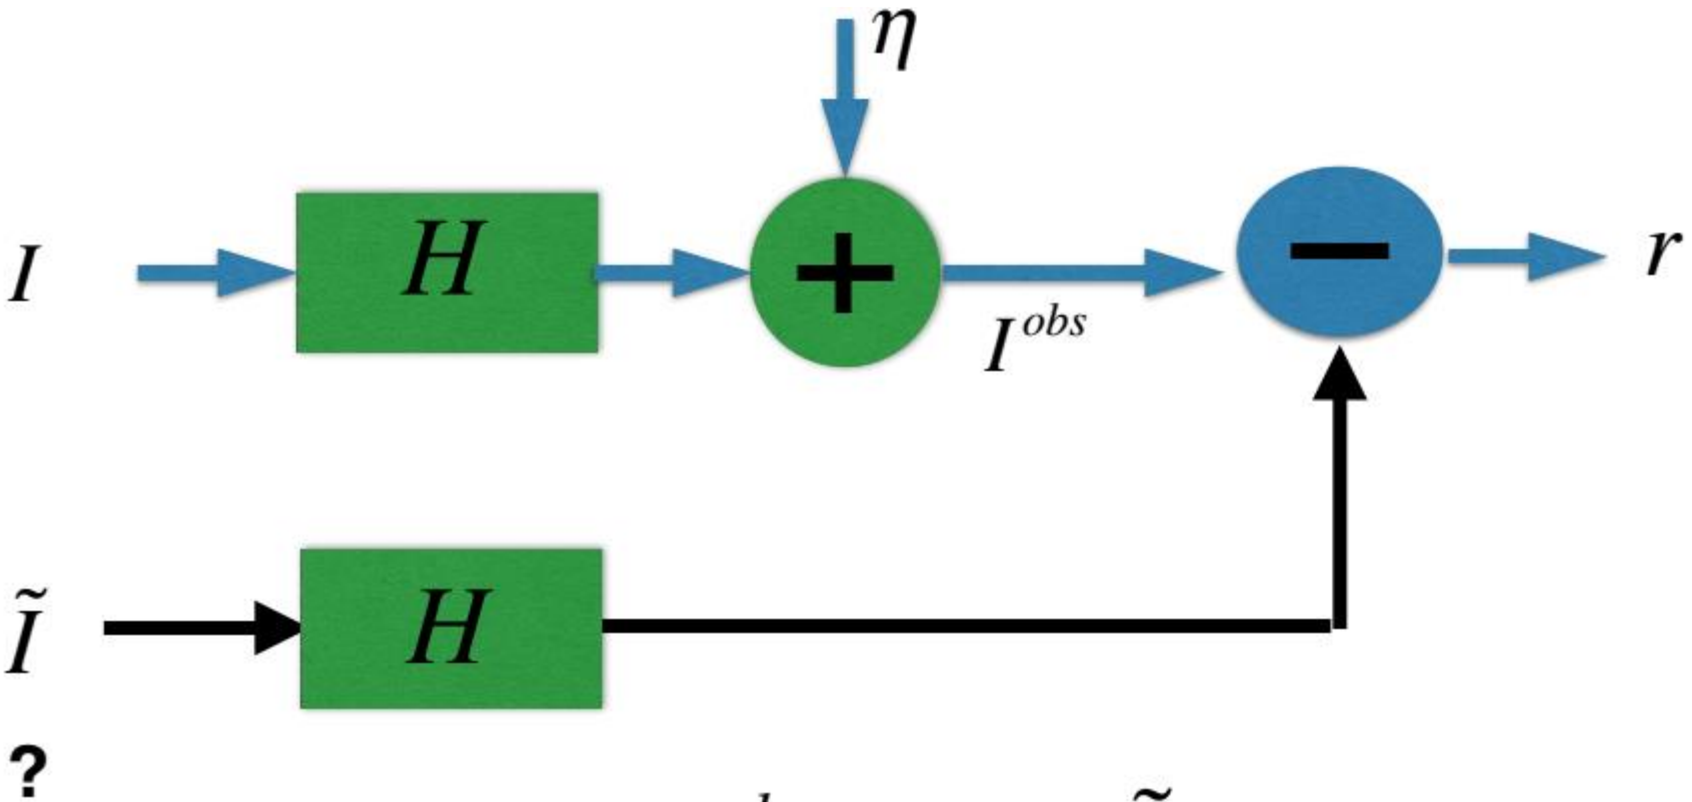

$$r = I^{obs} - H * \tilde{I}$$

直接从观察图像中恢复图像

受限最小二乘法过滤 (2/6)

- **约束优化问题（空域）**

$$\min_{\tilde{I}}\left\{\left\|R*\tilde{I}\right\|_2^2\right\}$$

平滑度测量

$$s.t.\quad \left\|I^{obs}-H*\tilde{I}\right\|_2^2=\left\|\eta\right\|_2^2$$

R：**离散拉普拉斯操作（二阶导数）**

H: 降低内核或点扩散函数

$*$：**卷积操作**

$$R=\begin{array}{|c|c|c|}\hline & 1 & \\ \hline 1 & -4 & 1 \\ \hline & 1 & \\ \hline\end{array}$$

受限最小二乘法过滤 (3/6)

- 无约束优化问题

$$J(\tilde{I}) = \lambda \left\| R * \tilde{I} \right\|_2^2 + \left(\left\| I^{obs} - H * \tilde{I} \right\|_2^2 - \left\| \eta \right\|_2^2 \right)$$

离散表示

$$= \underbrace{\lambda \sum_{p\in\Omega} \left\| \Delta \tilde{I}(p) \right\|_2^2}_{\text{平滑性条款 Tikhonov正则化}} + \underbrace{\sum_{p\in\Omega} \left(\left\| I^{obs}(p) - H * \tilde{I}(p) \right\|_2^2 - \left\| \eta(p) \right\|_2^2 \right)}_{\text{数据术语：解决方案的数据保真性}}$$

平滑性条款
Tikhonov正则化

L2

数据术语：
解决方案的数据保真性

（拉格朗日乘数法）

受限最小二乘法过滤 (4/6)

- 频域的等效优化问题

Parseval's theorem

$$J(\tilde{I}) = \lambda \left\| R * \tilde{I} \right\|_2^2 + \left(\left\| I^{obs} - H * \tilde{I} \right\|_2^2 - \left\| \eta \right\|_2^2 \right) \quad (\text{空域})$$

$$J(\hat{\tilde{I}}) = \lambda \left\| \hat{R} \cdot \hat{\tilde{I}} \right\|_2^2 + \left(\left\| \hat{I}^{obs} - \hat{H} \cdot \hat{\tilde{I}} \right\|_2^2 - \left\| \hat{\eta} \right\|_2^2 \right) \quad (\text{频域})$$

$$\frac{\partial J(\hat{\tilde{I}})}{\partial \hat{\tilde{I}}(u)} = \lambda \left\| \hat{R}(u) \right\|_2^2 \cdot \hat{\tilde{I}}^*(u) + \left(-\hat{I}^{obs*}(u) \hat{H}(u) + \left\| \hat{H}(u) \right\|_2^2 \hat{\tilde{I}}^*(u) \right) = 0$$

$$\boxed{\hat{\tilde{I}}(u) = \frac{\hat{H}^*(u)}{\left\| \hat{H}(u) \right\|_2^2 + \lambda \left\| \hat{R}(u) \right\|_2^2} \hat{I}^{obs}(u)}$$

$$\lambda = 0 \longrightarrow \text{逆向滤波器}$$

受限最小二乘法过滤

$$\hat{F}(u,v)=\left[\frac{H^*(u,v)}{|H(u,v)|^2+\gamma|P(u,v)|^2}\right]G(u,v)$$

$P(u,v)$ 是函数的傅里叶变换

$$p(x,y)=\begin{bmatrix}0 & -1 & 0\\ -1 & 4 & -1\\ 0 & -1 & 0\end{bmatrix}$$

γ 是参数

$$F(u,v)=\left[\frac{1}{H(u,v)}\frac{|H(u,v)|^2}{|H(u,v)|^2+K}\right]G(u,v).$$

参数调整

$$\hat{F}(u,v)=\left[\frac{H^*(u,v)}{|H(u,v)|^2+\gamma|P(u,v)|^2}\right]G(u,v)$$

- Set $\vec{r}=\vec{g}-\vec{H}\hat{\vec{f}}$

单调递增

$$\phi(\gamma)=\vec{r}^T\vec{r}=\|\vec{r}\|^2=\sum_{x=0}^{M-1}\sum_{y=0}^{N-1}r^2(x,y)$$

$R(u,v)=G(u,v)-H(u,v)\hat{F}(u,v)$,逆变换即为r(x, y)

调整 γ,

$$\|\vec{r}\|^2=\|\vec{\eta}\|^2\pm a$$

$$\|\vec{\eta}\|^2=\sum_{x=0}^{M-1}\sum_{y=0}^{N-1}\eta^2(x,y)=MN(\sigma_\eta^2+m_\eta^2)$$

1. 指定初始值 γ;
2. 计算r^2;
3. $\|\vec{\eta}\|^2$+/−a= r^2条件满足,则停止;
4. 如果大于,则减少γ值;如果小于,则增加γ值;根据新γ值计算最优估计

$$\sigma_\eta^2=\frac{1}{MN}\sum_{x=0}^{M-1}\sum_{y=0}^{N-1}[\eta(x,y)-m_\eta]^2$$

受限最小二乘法过滤 (6/6)

- 根据约束，最优 λ 可以迭代确定

$$r^k = I^{obs} - H * \tilde{I}^k$$

$$\varphi(\lambda^k) = \|r^k\|_2^2$$

$$\varphi(\lambda^k) \in \left[\|\eta\|_2^2 \pm a\right] \to \lambda^*$$

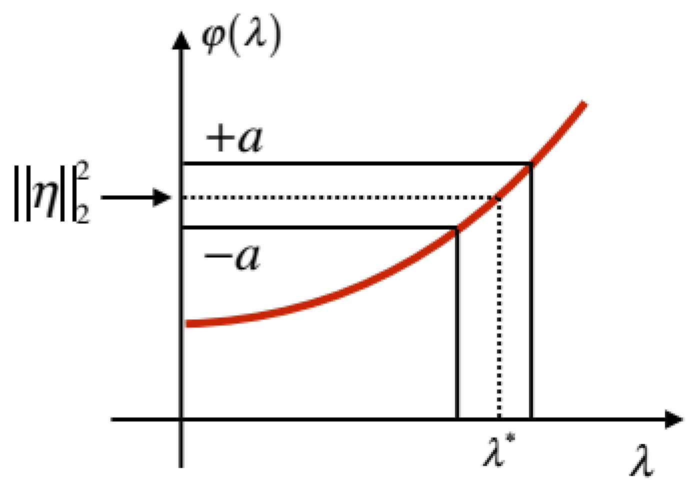

- 假设 : $\eta(p)$ iid $N(m_\eta, \sigma_\eta)$

$$\sigma_\eta^2 = \frac{1}{|\Omega|}\sum_{p\in\Omega}\left(\eta(p) - m_\eta\right)^2$$

$$\|\eta\|_2^2 = |\Omega| \cdot \left(m_\eta^2 + \sigma_\eta^2\right)$$

受限最小二乘法滤波的频率响应实例

$$H(u,v) = \operatorname{sinc}(ku)\cdot \operatorname{sinc}(kv)$$

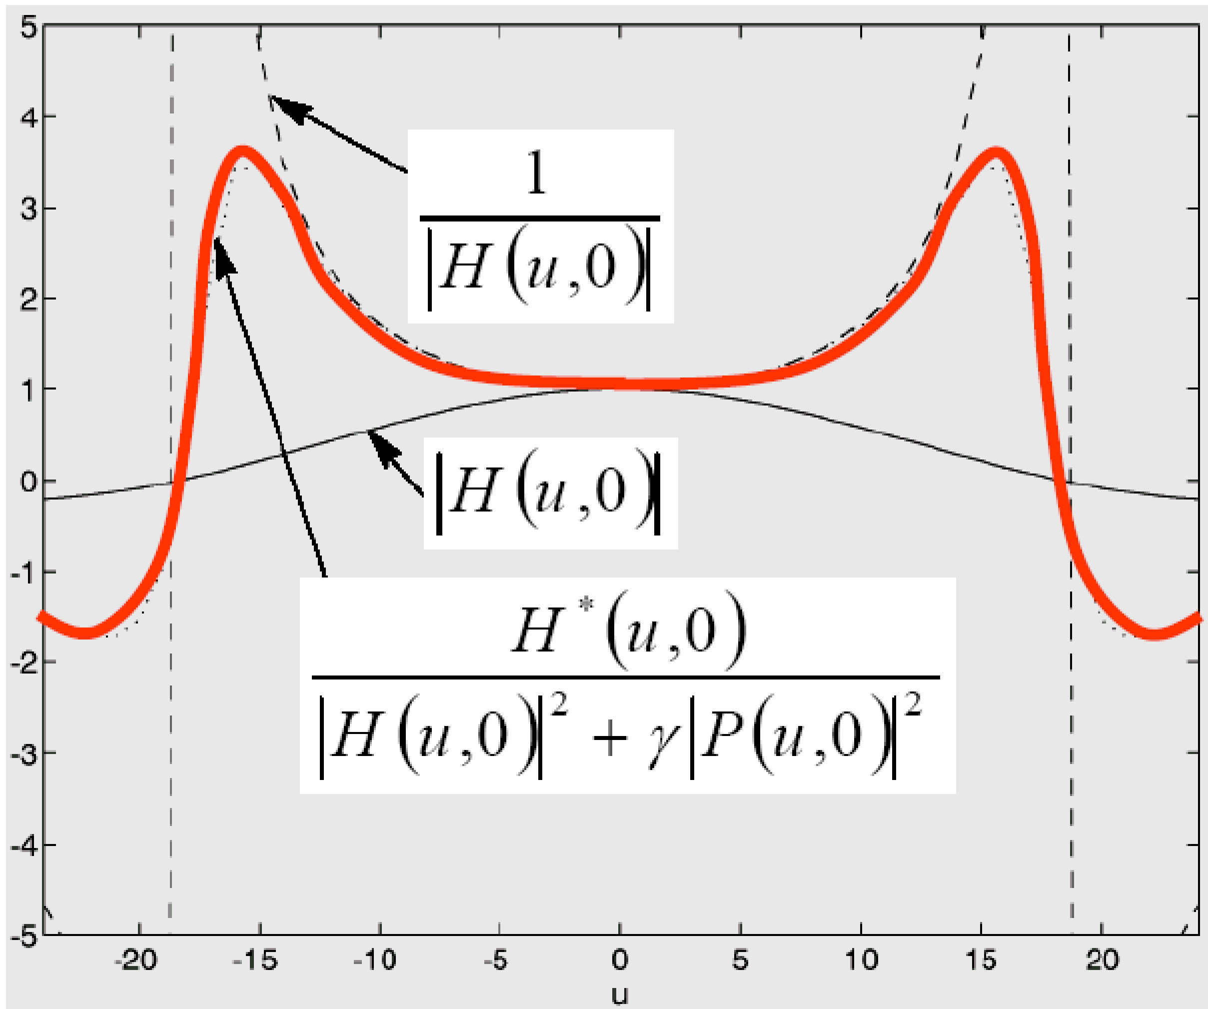

迭代确定 γ

- 指定初始值 γ
- 2) 计算

$$\phi(\gamma) = \sum \sum \left| G - H\hat{F} \right|^2$$

≈(5.9-6) 和 (5.9-7)

- 3) 停止如果 (γ) 足够小

否则选择一个新 γ 并到步骤 2.

例子 (CLSF)

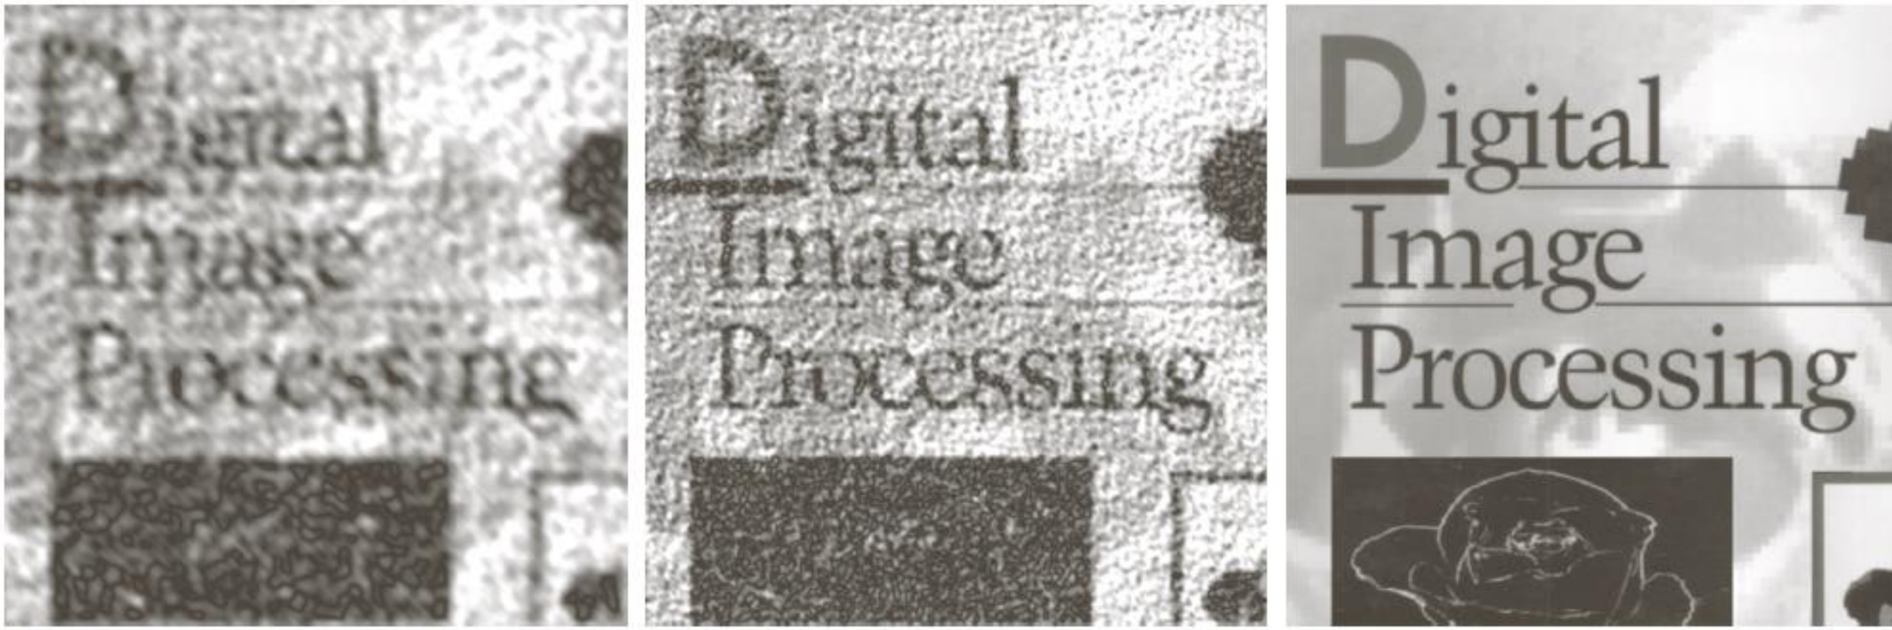

a b c

FIGURE 5.30 Results of constrained least squares filtering. Compare (a), (b), and (c) with the Wiener filtering results in Figs. 5.29(c), (f), and (i), respectively.

例子 (WF)


Digital
Image
Processing


Digital
Image
Processing

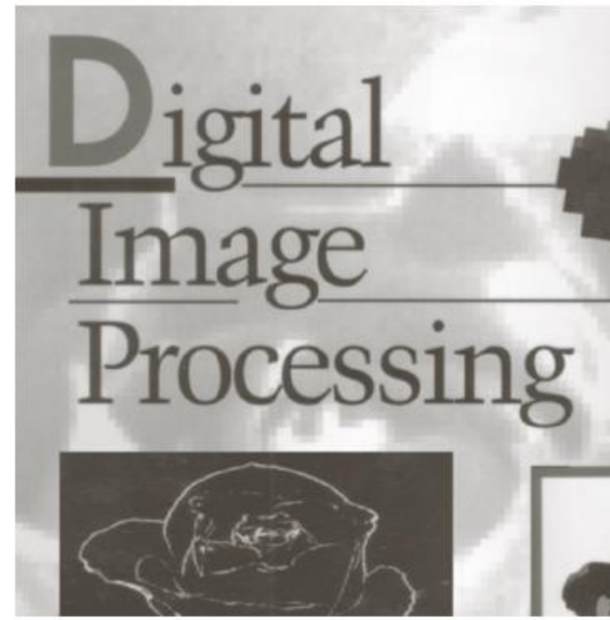
Digital
Image
Processing

受约束的最小二乘法
具有正确的噪声参数

受约束的最小二乘法
具有错误的噪声参数

$$\|\vec{\eta}\|^2 = \sum_{x=0}^{M-1}\sum_{y=0}^{N-1}\eta^2(x,y) = MN(\sigma_\eta^2 + m_\eta^2)$$

$$\sigma_\eta^2 = 10^{-5}$$

$$m_\eta^2 = 0$$

$$\sigma_\eta^2 = 10^{-2}$$

$$m_\eta^2 = 0$$

目录

- 退化-恢复模型
- 噪声模型
- 空域滤波器恢复
- 频域滤波恢复
- 线性位置不变退化
- 退化函数估计
- 逆滤波器
- 维纳滤波器-最小均方误差
- 约束最少方差滤波器
- 几何均值滤波器

几何平均数过滤器

$$\hat{F}(u,v)=\left[\frac{H^*(u,v)}{|H(u,v)|^2}\right]^{\alpha}\left[\frac{|H(u,v)|^2}{|H(u,v)|^2+\beta\left[S_\eta(u,v)/S_f(u,v)\right]}\right]^{1-\alpha}G(u,v)$$

$\alpha=1$: 逆向滤波器

$\alpha=0$: 参量维纳滤波器

$\alpha=1/2$: 几何平均滤波器

作业6

- 在测试图像上产生高斯噪声lena图-需能指定均值和方差；并用滤波器（自选）恢复图像；
- 推导维纳滤波器并实现下边要求；
  - (a) 实现模糊滤波器如方程Eq. (5.6-11).
  - (b) 模糊lena图像：45度方向，T=1；
  - (c) 再模糊的lena图像中增加高斯噪声，均值= 0 ，方差=10 pixels 以产生模糊图像；
  - (d)分别利用方程 Eq. (5.8-6)和(5.9-4)，恢复图像；